


『데이터베이스연구』 논문지 접수 양식

논문 정보	
논문 제목 (한글)	종단형 멀티모달 RAG 파이프라인 성능 향상을 위한 비순환 평가 및 검색 품질-비용에 대한 실증 연구
논문 제목 (영문)	An Empirical Study of Non-circular Evaluation and Retrieval Quality-Cost for Enhancing the Performance of End-to-End Multimodal RAG Pipeline
저자명	박천복1), Eduardo Linares1), 김승현1), 서영균2)† (Cheonbok Park, Eduardo Linares, Seunghyun Kim, Young-Kyoon Suht)
소속 및 직위	경북대학교 컴퓨터학부 석사과정1) 경북대학교 컴퓨터학부, 교수2)
세부 분야	데이터베이스, 정보검색, 멀티모달 데이터 관리
E-mail	박천복 cheonbok55@knu.ac.kr; Eduardo Linares edulinaro@knu.ac.kr; 김승현 seunghyeonkim010312@knu.ac.kr; 서영균 yksuh@knu.ac.kr
교신저자 정보 †	
성명	서영균
주소	대구 북구 대학로 80 IT-5호관 520호 (우편 41566)
연락처	053-950-6372



종단형 멀티모달 RAG 파이프라인 성능 향상을 위한 비순환 평가 및 검색 품질-비용에 대한 실증 연구

An Empirical Study of Non-circular Evaluation and Retrieval Quality-Cost for Enhancing the Performance of End-to-End Multimodal RAG Pipeline

요 약

대규모 영상 RAG 시스템은 벡터 데이터베이스의 데이터 저장 형태, 색인, 필터 조건 설계에 따라 검색 품질과 자원 비용이 결정되며 서로 상충 관계에 있다. 따라서 검색 품질-비용 효율을 왜곡 없이 입증하려면 데이터 저장부터 최종 모델의 답변 전파에 이르는 다차원적 통합 평가가 선행되어야 한다. 또한 데이터셋에 내재된 평가 순환성 문제를 정답 정보 유출을 차단함으로써 해결해야 한다. 이에 본 연구는 메타데이터, 영상 설명문, 사람 주석의 생성 경로를 분리한 비순환 평가 체계를 구축하고, 벡터 데이터베이스 설계 측에 따른 품질-비용 상충 관계와 VLM 답변 개선 효과를 종합 검증하였다. 실험 결과, 정답 주입 시 nDCG@10이 0.181에서 1.000까지 부풀려지는 왜곡을 규명하였다. 또한 다중 이미지 저장 시 검색 성능 대비 저장량(2.8배)과 지연 시간(3배)의 상충을 보였으며, 실측 군집의 근사 색인 재현율 손실은 조건별 부분 색인으로 98% 이상 복구함을 입증하였다. 결과적으로, 본 연구는 멀티모달 RAG의 검색 성능 왜곡을 차단하는 비순환 평가 체계를 정립하고, 제한된 시스템 자원 환경에서 최적의 검색 성능-비용 균형점을 도출하기 위한 종단 간 물리 설계 지침을 제시한다.

주제어 : 도시 교통 감시, 멀티모달, 벡터 데이터베이스, 시각 언어 모델, 검색 증강 생성

Abstract

In large-scale video RAG systems, search quality and system cost depend on how data is stored, indexed, and filtered in the vector database, creating a clear trade-off. Therefore, fairly evaluating search performance and cost requires an end-to-end test, from data storage to final model answers. Also, we need to fix circular evaluation in benchmark datasets by blocking answer data leaks. To address these challenges, we build a non-circular evaluation setup by separating the sources of metadata, video descriptions, and human annotations. Using this setup, we evaluate quality-cost trade-offs across vector database design choices and their impact on final VLM answers. Our experiments show that injecting ground-truth data inflates nDCG@10 from 0.181 to 1.000, proving severe metric distortion. Furthermore, multi-frame storage trades search performance for higher system cost, requiring 2.8× more storage space and 3.0× longer latency. Severe recall loss in approximate indexes caused by real-world data clustering is recovered to over 98% using partial indexes for specific conditions. Overall, this study sets up a fair evaluation standard for multimodal RAG and offers practical guidelines for choosing the best quality-cost trade-off under limited system resources.

Keywords: Urban Traffic Surveillance, Multimodal, Vector Database, Vision-Language Model, Retrieval-Augmented Generation

1. 서론

대규모 영상 데이터 집합에서 필요한 정보를 효율적으로 탐색하기 위해 영상의 시각 정보와 자연어 질의를 결합하는 멀티모달 영상 검색 증강 생성(Retrieval-Augmented Generation, RAG) 파이프라인이 현대 검색 시스템의 핵심 구조로 자리 잡았다. 이 파이프라인은 데이터베이스에서 사용자 질의와 관련된 소수의 핵심 영상 구간을 먼저 검색하고, 이를 시각 언어 모델(Vision-Language Model, VLM)에 참고 정보로 제공하여 생성 답변의 정확도를 높인다. 그러나 영상을 각 질의마다 VLM에 직접 입력하는 방식은 문맥 길이 상한 초과와 GPU 연산 비용 폭증을 유발한다[1]. 따라서 영상을 어떠한 형태로 적재하고 어떠한 색인과 필터 검색 계획을 적용하는지에 따라 시스템의 검색 품질과 물리적 자원 비용이 결정되므로, '데이터베이스 계층'의 물리 설계 최적화가 핵심 병목으로 부각된다[2].

데이터 저장 형태와 색인-검색 방식은 여러 분야에서 파편화되어 연구되어 왔다. VideoRAG[1]는 질의 관련 영상과 대표 이미지를 검색해 생성 모델에 제공하고, CLIP[3]과 같은 시각 언어 임베딩 모델은 영상 이미지와 자연어 질의 간의 벡터 유사도 검색에 사용된다. VBASE[4]와 ACORN[5]은 벡터 데이터베이스 시스템에서 구조화 조건과 벡터 유사도 검색을 결합하되, 주로 검색 실행 경로와 물리 색인의 성능에 초점을 맞추었다. 그러나 이러한 선행 연구들은 영상 질의 처리, 필터 결합 검색, 영상 언어 이해 기술을 개별 단위로만 발전시켰을 뿐, 데이터 적재부터 물리 색인, 배포 비용 및 최종 답변 효과까지 하나의 통합 파이프라인에서 측정하지 못했다.

더 근본적인 한계는 평가의 순환성이다. 기존 영상 벤치마크 데이터셋[6,7]들은 검색 성능 평가 단계에서의 '평가 순환성(Evaluation Circularity)[8]'과 '데이터 누수(Data Leakage)[9]' 문제가 내재되어 있다. 이는 질의, 메타데이터 필터, 영상 설명문, 검색 정답 집합이 하나의 동일한 사람 주석에서 파생함으로써 나타나는 구조적인 문제이다. 본 연구는 RAG 파이프라인에서 평가

순환성 실험을 모사했다. 그 결과, 정답 라벨을 검색 문서에 재진술하기만 해도 nDCG@10[10]이 0.181에서 0.854로 상승함을 보였다. 이는 실제 장면 이해가 아니라 주석 재사용이 성능으로 오인되고 있음을 보여준다.

본 연구는 메타데이터, 영상 설명문, 사람 주석의 3가지 데이터를 독립적으로 분리한 '비순환 작업 부하' 체계를 구축하여 정답 정보가 검색 대상으로 유출되지 않도록 차단한다. 이 체계는 정답 라벨과 토큰의 재사용을 자동으로 검사한다. 그리고 정답 기반의 조건 생성과 라벨을 의도적으로 재진술한 통제 실험을 수행하여 순환성이 검색 점수를 부풀리는 정도를 정량화한다. 또한 본 연구는 통합 평가의 부재를 해결하기 위해 저장 방식, 필터 조건, 검색 신호, 물리 색인, 배포의 비교 항목을 하나의 통합된 파이프라인에서 측정한다.

실험 결과, 순환성을 차단하자 부풀려졌던 지표가 현실적인 수준으로 조정되어 비순환 평가의 타당성이 입증되었다. 그리고 측정 결과에서 다중 이미지 저장 방식은 의미론적 검색 품질(nDCG@10)을 0.181에서 0.418로 높인다. 하지만 저장량(24.6MB→68.4MB)과 지연 시간(1.15ms→3.65ms)이 대폭 증가하여 상충 관계임이 확인되었다. 또한 전역 근사 색인이 시공간 군집 조건에서 유발하는 재현율 손실(최대 0.627)을 규명하였으며, 조건별 부분 색인이 이를 98.12~100% 복구함을 입증하였다. 단, 데이터베이스 계층의 검색 성능 개선이 최종 VLM 답변 품질로 자동 전파되지는 않았다.

본 연구의 공헌은 다음과 같다.

- 본 연구는 데이터 원천을 독립 분리하여 평가 순환성 및 데이터 누수를 차단하는 비순환 평가 체계를 수립하고, 검색 성능 지표의 부풀림 현상을 정량적으로 진단한다.
- 본 연구는 저장 방식, 필터 조건, 검색 신호, 물리 색인, 배포 비용을 통합한 파이프라인에서 다차원적으로 설계하여 검색 성능과 자원 비용을 정밀 측정한다.
- 본 연구는 검색 개선이 생성 모델의 답변 품질로 전파되는 인과 경계를 밝혀, 멀티모달 RAG의 종단 간 최적화 지침을 도출한다.

본 논문의 구성은 다음과 같다. 2장은 관련 연구를 정리하고, 3장은 데이터베이스 계층의 비순환 조건부 설계 선택 문제를 정의한다. 4장은 비순환 평가 작업 부하와 데이터베이스 계층 설계 공간을 포함한 방법론을 설명한다. 5장은 여섯 연구 질문에 따라 실험 결과를 분석하고, 6장은 결론과 향후 연구를 제시한다.

2. 관련 연구

데이터 누수는 목표 정보를 특징이나 평가 자료에 다시 사용하여 실제 운용보다 높은 성능을 만든다[7]. 그리고 같은 자료에서 학습과 평가 기준을 구성하는 순환성은 도구 간 비교를 왜곡한다[8]. 검색 문서-질의-검색 정답 집합이 같은 주석에서 파생되면 검색기의 장면 이해와 평가 자료가 제공한 단서를 분리하기 어렵다. 본 연구는 이 원리를 벡터 데이터베이스 검색 작업 부하로 확장하여 센서 기록-영상 설명문-사람 주석을 분리하고, 정답 기반 조건과 라벨 재진술을 각각 주입한 통제 실험을 바탕으로 정답 정보의 재사용이 검색 점수를 부풀리는지 확인한다.

RAG는 사용자 질의에 부합하는 외부 지식을 먼저 검색하고, 이를 생성 모델에 참고 정보로 제공하여 답변의 신뢰성을 높이는 기술이다. VideoRAG는 이를 영상 코퍼스로 확장하고, CLIP은 이미지와 텍스트를 공통 벡터 공간에 배치해 이미지 검색으로 확장한다. 본 연구는 이러한 검색 대상 데이터를 단순한 생성 모델용 입력으로만 두지 않고, 데이터베이스에 물리적으로 저장되어 벤치마킹되는 실제적 대상으로 취급한다. 이에 따라 영상 설명문, 대표 이미지, 다중 이미지, 이미지-설명문 결합 벡터와 이중 색인 구조를 동일한 질의와 정답 기준에서 검색 품질-지연 시간-저장 용량으로 비교한다. 각 검색용 데이터가 최종 VLM 답변에 미치는 영향은 관련 설명문과 카메라 시점을 대상으로 한 별도의

답변 실험에서 검증한다.

메타데이터 조건은 근사 최근접 이웃(ANN) 검색 전·후 또는 탐색 과정에 적용할 수 있으며, 그 성능은 조건 통과 비율뿐 아니라 통과 벡터의 공간 분포와 색인의 탐색 구조에 좌우된다[11]. VBASE는 관계형 질의처리와 벡터 검색을 연결하고, 반복 탐색은 pgvector[12], 그래프 탐색과 조건 처리는 Milvus[13]와 ACORN에서 다뤄졌다. 본 연구는 메타데이터 조건을 필수 제약과 관심 단서로 구분해 평가한다. 같은 수의 벡터를 통과시키는 무작위 조건과 실측 장소-시간 조건을 짝지어 비교하고, 두 조건의 차이가 벡터 검색 라이브러리와 실제 벡터 데이터베이스에서도 나타나는지 확인한다.

VRU-Accident[6]과 UCA[14]는 사고·이상행동 영상을 자연어 질의 및 답변과 연결한다. Spatialize[15]는 시공간 조건을 이용해 영상 분석 대상을 축소한다. 이들 연구는 도시 감시 장면을 언어로 질의하거나 메타데이터 조건으로 처리 범위를 줄인다는 점에서 본 연구와 결을 같이한다. 다만 이들의 초점은 영상 이해 모델, 검색 파이프라인, 답변 정확도에 있다. 반면 본 연구는 검색용 데이터의 저장 방식, 메타데이터(필터) 조건 적용, 검색 신호, 물리 색인, 배포 비용을 비순환 평가 아래 설계 축별로 비교한다. 또한 검색 단계의 차이가 최종 답변으로 전파되는 조건을 별도로 검증한다.

기존 연구는 영상 질의 처리, 필터 결합 벡터 검색, 영상 언어 이해를 각각 발전시켰다. 그러나 평가 자료의 생성 경로부터 저장 방식, 메타데이터 조건, 검색 신호, 물리 색인, 배포 비용과 최종 답변의 효과까지 하나의 절차에서 함께 비교하지는 않았다. 본 연구는 비순환 작업 부하를 먼저 확립하고, 각 설계 선택의 검색 품질과 비용을 비교한 뒤 검색 결과가 답변으로 전파되는 조건을 검증하여 이 공백을 메운다.

3. 문제 정의

본 연구가 다루는 문제는 두 가지다. 첫째, 기존 도시 감시 영상 검색 평가 환경에서는 질의, 메타데이터 조건, 검색용 문서 및 검색 정답 집합이 동일한 사람 주석에서 함께 파생됨으로써 발생하는 '평가 순환성'으로 인해 검색 품질 지표가 비정상적으로 왜곡되는 문제가 발생한다. 메타데이터 조건·검색 문서·질의·검색 정답 집합이 단일 출처에서 만들어지면 필연적으로 데이터 누수가 발생한다. 이는 검색기가 영상의 실제 시각 장면을 이해하지 못하더라도 정답 정보의 재사용으로 인해 검색 점수가 부풀려지므로 데이터베이스 계층의 올바른 구조적 벤치마크 및 비교 분석을 방해한다[8,9].

둘째, 순환성을 차단하더라도 검색용 데이터·검색 계획·검색 신호·물리 색인·배포의 최적 구성은 하나로 고정되지 않고, 무엇을 관련 영상으로 인정할지(정답 기준)와 서비스 비용 제약에 따라 달라진다. 따라서 본 연구의 문제는 하나의 검색 점수를 최대화하는 것이 아니라, 비순환 평가 아래에서 서비스가 요구하는 재현율·지연 시간·저장량·구축 비용 한도를 만족하는 후보 중 사용 목적에 맞는 정답 기준의 검색 품질이 가장 높은 데이터베이스 계층 구성을 선택하는 것이다.

이 문제를 정의하려면 데이터베이스 계층의 입력과 출력, 그리고 정답 기준을 밝혀야 한다. 데이터베이스 계층은 원본 영상과 센서 메타데이터, 미리 생성한 영상 설명문·벡터를 저장하고, 자연어 의미 조건과 메타데이터 조건, 반환 수를 입력받아 상위 영상 클립을 반환한다. 각 결과에는 식별자, 원본 위치, 촬영 시간, 검색 점수와 메타데이터가 포함된다. 동일한 메타데이터 조건도 사용자 의도에 따라 반드시 지켜야 하는 필수 제약이거나 검색 대상을 설명하는 관심 단서일 수 있다. 필수 제약일 때는 의미 조건과 메타데이터 조건을 모두 만족하는 항목을 '엄격한 정답'으로 정의하여 조건

준수 여부를 평가하고, 관심 단서일 때는 의미 조건을 만족하는 모든 항목을 '의미론적 정답'으로 정의하여 조건 적용으로 관련 영상이 제외되는지를 평가한다. 이 두 가지의 '정답 기준'은 이후 검색 계획을 해석하는 바탕이 된다.

최적 구성이 하나로 정해지지 않는 것은 설계 측면마다 상충의 방향이 다르기 때문이다. 예를 들어 더 상세한 검색용 데이터는 검색 품질을 높이지만 저장량과 지연 시간을 늘리고, 메타데이터 조건을 강하게 적용하면 조건은 잘 지키지만 관련 영상을 놓칠 수 있다.


끝으로, 이렇게 고른 구성이 검색 품질을 높이더라도 그 개선이 최종 VLM 답변으로 전파되는지는 별개의 문제다. 본 연구는 이 전파 조건을 증거 회수, VLM의 증거 인식, 과제 편향으로 나누어 답변 전파 실험에서 검증한다.

4. 방법론

그림 1은 세 원천 자료의 분리부터 데이터베이스 계층의 설계 비교와 답변 효과 검증까지 이어지는 본 연구의 전체 절차를 나타낸다. 이 절차는 먼저 비순환 작업 부하를 통해 평가 타당성을 확보하고, 다음으로 데이터베이스 계층의 설계 항목들을 비교한다. 마지막으로 검색 결과의 차이가 최종 VLM 답변으로 전파되는지를 검증한다. 각 비교 안에서는 분석 대상 축만 변경하고, 질의·코퍼스·정답 및 모델 설정은 동일하게 유지한다.

4.1. 비순환 작업 부하 구성과 순환성 진단

데이터 누수와 평가 순환성이 있으면 시스템이 영상 픽셀을 실제로 이해하지 못해도 성능 지표가 실제보다 높게 나올 수 있다[8,9]. 본 연구는 이 문제를 데이터베이스 검색 평가에 적용하여 기존 데이터셋을 그대로 재사용하지 않고 정답 정보의 유입을 차단한 비순환 평가 작업 부하를



<그림 1> 비순환 작업 부하, 데이터베이스 계층 설계 및 VLM 답변 전파 분석 파이프라인

설계한다. 이를 위해 메타데이터 조건은 센서 기록에서, 검색 문서는 영상 픽셀과 고정 프롬프트만을 입력받은 VLM이 생성한 설명문에서, 의미 검색 정답 집합은 사람 주석에서 각각 구성하여 세 원천의 생성 경로를 분리한다.

본 연구는 정답 영상을 가려내는 데 사용한 라벨이나 주석을 메타데이터 조건 또는 검색 문서에 다시 사용하는 경우를 순환성으로 정의한다. 질의는 사용자가 찾고자 하는 내용을 포함하고, 정답은 그 내용을 실제로 담고 있는 한 영상이므로 두 요소의 의미가 일치하는 것이 검색 결과의 관련성을 평가하기 위한 기본 조건이다. 순환성 검사는 메타데이터 조건과 검색 정답 집합의 출처가 확실하게 분리되었는지, 메타데이터에 정답 필드가 포함되지 않았는지, 검색 문서에 정답 라벨이나 내부 필드명이 직접 노출되었는지를 자동으로 확인한다.

비순환 작업 부하를 구축한 뒤에는 정답 정보를 의도적으로 다시 주입하여 순환성이 검색 성능을 얼마나 왜곡하는지 진단한다. 첫 번째 통제 주입(정답 조건 주입)은 정답 정보를 메타데이터 조건에 반영하여 정답 영상만 검색 후보로 남긴다. 두 번째 통제 주입(정답 라벨 재진술 주입)은 정답 정보의 의미를 문장 형태로

풀어 정답 영상과 대응하는 검색 문서에 추가한다. 두 실험은 정답 정보가 각각 메타데이터 조건과 검색 문서를 통해 유입될 때 발생하는 점수 상승을 측정한다.

첫 번째 통제 주입에서는 질의별 정답 영상만 통과시키는 조건을 적용한다. 하지만 정답 기반 조건은 검색 후보 수를 줄이는 동시에 정답 영상만 남기므로, 성능 상승이 후보 수 감소에서 비롯된 것인지 정답 정보의 사용에서 비롯된 것인지 그 결과만으로 구분하기 어렵다. 이를 구분하기 위해 각 질의의 정답 영상 수와 동일한 수의 영상을 전체 코퍼스에서 무작위로 선택하는 대조 조건을 구성한다. 본 연구에서는 이러한 무작위 선택을 1,000회 반복하여 동일한 선택도에서 나타나는 성능 분포를 산출하고, 이를 정답 기반 조건의 성능과 비교한다.

두 번째 통제 주입에서는 각 정답 영상의 캡션에 해당 영상이 정답인 이유를 직접 설명하는 문장을 추가한다. 이를 통해 원본 캡션을 사용한 결과와 정답을 재진술한 문장을 추가한 결과를 비교하여 정답을 암시하는 텍스트가 검색 문서에 포함될 때 점수가 얼마나 상승하는지 측정한다. 각 통제 주입에서는 질의, 코퍼스, 검색 정답 집합과 임베딩 모델을 동일하게 유지하고 주입 대상만 변경한다.

4.2. 데이터베이스 계층 설계 및 비교 측정의 정의

본 연구는 데이터베이스 계층을 다섯 설계 축으로 정의한다. ‘검색용 데이터’는 mp4 포맷의 영상 클립의 시각 정보를 검색 가능한 형태로 변환하여 데이터베이스에 저장하는 형식이다. 클립 전체를 요약 서술한 텍스트 기반의 *영상 설명문*, 클립을 대표하는 단일 프레임 이미지 기반인 *대표 이미지*, 두 정보를 단일 벡터로 융합한 *이미지-설명문 결합*, 한 클립에서 여러 장의 주요 프레임을 추출해 각각 저장하는 *다중 이미지*, 그리고 설명문 텍스트와 다중 이미지 색인을 독립 구축하여 순위를 융합(Reciprocal Rank Fusion, RRF)[17]한 *설명문-이미지 이중 색인*으로 구성된다.

‘검색 계획’은 조건을 언제 어떻게 적용할지를 정하는 방식이다. 조건 없이 벡터 유사도만으로 찾는 *벡터 단독 검색*, 조건을 통과한 부분집합 안에서만 벡터를 검색하는 *검색 전 조건 적용*, 벡터 상위 후보를 먼저 찾은 뒤 조건에 맞지 않는 결과를 제거하는 *검색 후 조건 적용*, 그리고 사전 필터로 좁힌 부분집합에서 어휘와 벡터 순위를 역순위 융합하는 복합 계획인 *혼합 검색*으로 구성한다. 조건을 반드시 지켜야 하는 필수 제약으로 불지(엄격한 정답) 검색을 돕는 관심 단서로 불지(의미론적 정답)도 검색 계획 해석에 포함된다.

‘검색 신호와 순위 융합’은 순위를 매기는 근거와 서로 다른 신호가 만든 순위를 하나로 합치는 방식을 함께 다루는 축이다. 필터를 통과한 클립을 식별자 순서대로 반환하여 조건과 의미 관련성의 결합도를 재는 기준선인 *메타데이터 단독*, 설명문 텍스트의 어휘 일치로 순위를 매기는 *BM25 어휘*[16], 임베딩 유사도로 순위를 매기는 *벡터*, 그리고 어휘와 벡터의 두 순위를 역순위 점수로 합산하는 *BM25-벡터/RRF*으로 구분한다.

‘물리 색인’은 벡터를 저장하고 탐색하는 자료구조다. 모든 벡터를 전수 비교하는 정확 검색

Flat, 그래프를 따라 이웃을 좁혀 가는 근사 색인 *HNSW*[18], 벡터를 여러 군집으로 나눈 뒤 일부 군집만 탐색하는 *IVF-Flat*, 그리고 IVF 구조에 벡터를 압축해 저장량을 줄인 *IVF-PQ*로 구성한다.

‘배포’는 색인을 어떤 범위로 구축해 운영할지를 정하는 방식이다. 전체 데이터를 하나로 색인하는 *전역 색인*, 자주 쓰는 조건별 부분집합만 따로 색인하는 *조건별 부분 색인*으로 구성한다.

혼합 검색은 메타데이터 조건으로 후보를 먼저 제한한 뒤, 남은 후보에서 BM25 순위로 나온 결과와 벡터 순위로 나온 결과를 RRF로 결합하여 단일 최종 순위를 도출한다. 따라서 검색 계획 비교에서는 혼합 검색을 하나의 결합된 실행 방식으로만 평가하고, 순위 융합 자체의 효과는 검색 신호 비교에서 따로 분리한다.

혼합 검색은 BM25가 필요한 텍스트 문서를 갖춘 영상 설명문에만 적용할 수 있다. 여기서 영상 설명문은 4개 검색 계획을 모두 지원하지만, 나머지 4개의 검색용 데이터는 3개 검색 계획만 지원한다. 이에 따라 유효한 검색용 데이터-검색 계획 조합은 $1 \times 4 + 4 \times 3 = 16$ 개다. 이를 4개의 물리 색인과 HNSW의 efSearch 설정(64, 256), 그리고 IVF에서 nprobe 설정(8, 32)을 고려하여 총 7개의 설정과 결합한다. 이를 통해 총 $16 \times 7 = 112$ 개 구성에서 성능을 측정한다.

5. 실험

본 장은 실험에 사용한 여섯 연구 질문(RQ)을 정의하고, 이를 실제 데이터에 적용하여 검증한다. 평가 타당성부터 답변 전파까지의 의존 순서에 따라 RQ1을 먼저 검증한 뒤 RQ2-RQ5의 설계 축을 비교하고, 마지막으로 RQ6의 답변 효과를 확인한다.

- **비순환 평가 타당성(RQ1).** 같은 주석의 재사용은 검색 점수를 얼마나 왜곡하며, 본 연구의 세 원천

<표 1> AI Hub 교차로 주 평가 데이터와 목적별 보완 데이터

구분	데이터	규모	검색용 데이터	정답·메타데이터 조건의 출처	역할
주 평가	AI Hub 교차로[19]	설명문 3,000개, 질의 85개	픽셀 기반 영상 설명문	사람 주석 정답, 센서 조건	핵심 설계 축 통제 비교 (RQ2-RQ4)
목적별 보완	VRU-Accident [6]	설명문 1,000개, 질의 85개, 답변 문항 600개	제공 설명문	사고 유형 정답, 날씨·도로·장소 조건	순환성·설명문 증거 대조 (RQ1, RQ6)
	지능형 관제 CCTV[7]	설명문 269개, 질의 18개	한국어 사건 설명문	사건 정답, 야간·장소 조건	순환성 외부 사례 (RQ1)
	MEVA[20]	클립 985개, 질의 193개	영상 설명문, 대표 이미지	사람 활동 정답, 촬영 위치·시각 조건	검색용 데이터 외부 대조 (RQ2)
	UCA/UCF-Crime [14]	세그먼트 6,432개, 질의 135개(분석 129개)	픽셀 기반 세그먼트 설명문	사람 문장 어휘 정답, 사건·길이·시점 조건	조건 결합 외부 대조 (RQ3)
	시내도로 이미지[21]	벡터 132,521개(512차원), 실측 조건 29건	CLIP 이미지 벡터	조건별 Flat 상위 이웃, 시공간 조건	대규모 근사 색인 평가 (RQ5)
	AI Hub 교차로 이미지[9]	벡터 143,830개(512차원), 실측 조건 25건	CLIP 이미지 벡터	조건별 Flat 상위 이웃, 조인 센서 조건	대규모 근사 색인·전파 예비 평가 (RQ5, RQ6)
	MIRIS[22]	벡터 59,019개(512차원)	CLIP 이미지 벡터	조건별 Flat 상위 이웃, 장면·스트림 구간	부분 색인 배포 대조 (RQ5)
	다각도 CCTV[23]	400사건(주 분석 250개)	시점별 이미지	시각 질의응답(VQA)의 정답, 경계 상자 기반 시점 비대칭	카메라 시점의 답변 효과 (RQ6)

분리 프로토콜은 이를 진단하고 차단할 수 있는가?

- 검색용 데이터 구성(RQ2). 영상 설명문, 대표 다중 이미지, 이미지 설명문 결합 벡터와 이중 색인은 검색 품질·지연·시간·저장 공간에서 어떤 절충을 만드는가?
- 검색 계획(RQ3). 벡터 단독 검색과 검색 전·후 조건 적용, 혼합 검색은 조건이 필수 제약인지 관심 단서인지 및 조건·관련성 결합도에 따라 어떻게 달라지는가?
- 검색 신호와 순위 융합(RQ4). 메타데이터, BM25 어휘, 벡터 신호는 순환 요소를 제거한 뒤에도 독립적인 검색 이득을 제공하며, 약한 어휘 신호의 순위 융합은 순위를 개선하는가?
- 물리 색인과 배포(RQ5). 실측 조건의 선택도·군집성과 질의 빈도에 따라 Flat, HNSW/IVF 계열과 전역·부분 색인을 어떻게 선택해야 하는가?

- 답변 전파(RQ6). 검색 결과의 차이가 최종 답변으로 전파되려면 증거 회수, VLM 인식과 과제 편향에서 어떤 조건을 충족해야 하는가?

5.1. 환경 설정

5.1.1. 데이터셋

표 1은 각 데이터셋의 규모와 역할을 요약한다. 본 연구의 통제 비교는 메타데이터 조건·검색 문서·검색 정답 집합이 서로 다른 원천에서 제공된 경우에만 순환성 없이 성립하지만, 대부분의 감시 영상 데이터셋은 이 세 정보를 하나의 사람 주석에서 파생하여 순환 위험을 안는다. AI Hub 교차로 데이터셋은 센서 기록에서 메타데이터 조건, 영상 픽셀에서 검색 문서, 사람 주석에서 검색 정답 집합을 각각 독립적으로 얻을 수

<표 2> 공통 실행 환경과 변인 통제 명세

구분	세부 사양 및 설정	변인 통제 및 제외 범위
장비	Intel i7-9700K, 메모리 62GB, RTX 3090 24GB 2대, Linux 5.15	네트워크 지연 배제를 위해 동일 호스트에서 로컬 실행
소프트웨어	Python 3.10.20, Faiss 1.14.3, PostgreSQL 16.14, pgvector 0.8.4, Milvus 2.6.0, Weaviate 1.35.3	전 과정 엔진·라이브러리 버전 고정
영상 설명문 생성	Qwen2.5-VL-7B-Instruct, 중간 이미지, 최대 110토큰, 탐욕적 디코딩	사전 구축 작업이므로 검색· 색인 지연 비용에서 제외
임베딩	BGE-M3 1,024차원, CLIP ViT-B/32 512차원, Qwen3-VL-Embedding-2B 2,048차원, L2 정규화	온라인 질의 임베딩 생성 지연은 측정에서 제외
Faiss 통제	CPU 단일 스레드, RQ2 준비 2회·반복 10회, RQ5 준비 실행 제외·반복 15회	병렬화 왜곡 방지, 검색·조건 적용· 결과 통합·순위 융합(RRF) 시간 포함
pgvector 통제	단일 커넥션, 실행 시점 컴파일 비활성화, 준비 2회·반복 5회, 질의 300개	커넥션 풀링·실시간 최적화 잡음 차단, 왕복 시간·조건 적용·상위 k 개 반환 포함

있어 세 원천 소스 분리가 효율적이다. 또한 63개 교차로의 동기화 다중 카메라와 시공간·신호 조건이 만드는 현실적 군집성, 그리고 검색 품질 비교와 대규모 근사 색인 평가를 함께 감당할 규모를 갖춘다. 이러한 조건 덕분에 코퍼스질의 엄격한 및 의미론적 두 정답 기준을 고정한 핵심 설계 축의 주 평가 데이터로 사용할 수 있다. 이외의 목적별 보완 데이터는 주 평가 데이터만으로 확인하기 어려운 특정 설계 조건이나 외부 타당성을 검증하며, 해당 RQ에서만 사용한다.

AI Hub 교차로 데이터셋에서 센서 채널인 카메라 10은 시간·신호·교통량이 기록된 클립 32,880개, 시각 채널인 카메라 11과 22는 영상 클립 52,462개를 제공한다. 이 중 사람 주석과 연결된 52,210개에 대해 같은 교차로에서 촬영 시각 차이가 ± 120 초 이내인 가장 가까운 센서 클립을 연결하여 47,098개의 시각 클립을 확보했다. 각 클립의 중간 이미지를 Qwen2.5-VL-7B-Instruct[24]에 입력하고, 교통량·차종·정차 및 주차 차량·보행자·도로·날씨 중 화면에 보이는 내용을 2-4문장으로 설명하도록 했다. 모델에는 픽셀과 프롬프트만 제공하고 센서

기록과 사람 주석은 제공하지 않았으며, 생성은 최대 110토큰의 탐욕적 디코딩을 사용했다.

질의는 시간대, 시각, 황색 신호, 보행 신호와 센서 교통 밀도의 메타데이터 조건 5종에 주차 차량, 개체 20개 이상, 버스 2대 이상, 정차 차량과 이륜차 2대 이상의 의미 조건 5종을 결합해 만들었다. 메타데이터 필드의 구체적인 조건값 22개와 의미 조건 5개의 조합에서 후보 110개를 만들고, 두 조건을 함께 만족하는 클립이 5개 이상인 질의 85개를 확정했다.

5.1.2. 실행 환경

표 2는 본 연구의 공통 실행 환경과 측정 명세를 요약한다. 데이터베이스 검색 지연 시간을 정확히 계측하기 위해, 초기 메모리 캐시 적재 효과를 배제하는 워업 방식을 적용하고 Faiss[25] 연산은 단일 CPU 스레드, pgvector 연산은 단일 커넥션으로 제한하여 하드웨어적 병렬화와 임시 캐싱에 의한 측정 왜곡을 차단한다.

임베딩 모델은 각 실험이 비교하는 표현의 형태에 맞추어 선택한다. 검색용 데이터 형식 비교는 이미지 이미지와 설명문 텍스트를 하나의 벡터 공간에 두어야

하므로 Qwen3-VL-Embedding-2B[26]를 멀티모달 임베딩으로 사용한다. 설명문 생성 모델 비교와 검색 계획 및 신호 비교는 텍스트 설명문만 다루므로 텍스트 임베딩 BGE-M3[27]를 사용한다. 대규모 이미지 색인 실험은 이미지 벡터를 대규모로 색인하므로 이미지 임베딩 CLIP ViT-B/32[3]를 사용한다. 개별 실험군 내에서는 동일한 임베딩 모델을 고정 적용하여 각 구성 간 검색 품질을 동일 척도인 nDCG@10으로 비교하며, 서로 다른 임베딩을 사용하는 실험군 간에는 상대적 차이를 중심으로 결과를 해석한다.

데이터베이스 계층 112개 구성의 통합 비교 실험에서 물리 색인은 Flat, HNSW, IVF-Flat, IVF-PQ를 사용한다. 여기서 HNSW는 노드당 최대 연결 수(M)=32, 색인 구축 시 탐색 범위(efConstruction)=200으로 구축한 뒤 검색 시 탐색 범위(efSearch)=64와 efSearch=256을 비교하며, IVF 계열은 총 군집 수(nlist)=64로 구축한 뒤, 검색 대상 군집 수(nprobe)=8과 nprobe=32를 비교하고, IVF-PQ는 분할 부분공간 수(m)=32와 6비트 부동소수점 양자화를 적용한다.

데이터베이스 적재 시 영상 설명문, 대표 이미지, 이미지·설명문 결합은 클립당 한 건을 저장하고, 다중 이미지는 클립당 최대 세 건을 저장하며, 설명문·이미지 이중 색인은 설명문 한 건과 최대 세 이미지를 각각 검색한 뒤 상수 60의 RRF로 결합하여 평가한다.

혼합 검색은 어휘 문서가 확보된 영상 설명문에 한해 적용하며, 검색 후 조건 적용은 벡터 검색 결과 상위 200개 후보군에서 조건에 부합하는 결과를 필터링한다. 이 코퍼스 환경에서 질의 85개, 엄격한 정답 6,809행, 의미론적 정답 24,872행을 고정하여 총 19,040건의 구성·질의·평가 계약 품질을 측정하고, 지연 시간은 질의당 10회씩 총 95,200회 반복 측정하여 성능을 평가한다.


5.1.3. 평가 방법

본 연구는 검색 품질 지표와 물리적 비용 지표를 입체적으로 평가하여 데이터베이스 계층 설계의 실무적 타당성을 검증한다. 검색 품질은 정규화 할인 누적 이득(nDCG@10)과 검색 정답 집합 재현율(Recall@10)을 기준으로 평가한다. nDCG@10은 최종 답변을 생성하는 VLM에 탑재될 관련 증거가 상위 순위에 조밀하게 정렬되어 있는지를 나타내는 지표이며, Recall@10은 제한된 입력 문맥 크기 내에 핵심 증거가 누락 없이 포함되었는지의 상한선을 결정하는 실무적 지표로 사용된다. 근사 최근접 이웃의 정확도 평가는 Flat 전수 검색 성능을 기준으로 한 상대적 재현율(Recall@10)을 사용하며, 이는 알고리즘적 색인 손실과 데이터베이스 필터링 전략에 따른 손실을 독립적으로 분리하여 진단하기 위함이다. 시스템 비용은 직렬화된 색인 크기, 색인 구축 시간, 그리고 준비 실행을 제외한 질의별 지연 시간(p50 및 p95)으로 제한하며, 특히 지연 시간 p95는 실시간 도시 관제 시스템의 서비스 수준 계약 충족 여부를 판단하는 주요 최악 조건 지표로 활용한다. 절대 지연 시간은 시스템 계층 범위의 차이에 따른 잡음을 방지하기 위해 동일 데이터베이스 내에서만 상대 비교한다.


검색 계획의 효과가 질의와 필터 조건 간의 상관관계에 따라 어떻게 변화하는지 규명하기 위해, 질의 85개를 메타데이터 조건 통과 여부와 의미 관련성 간의 상관성을 나타내는 Cramér's V[28] 계수를 기준으로 층화 분석(Stratified Analysis)한다. 구체적으로 계수 0.3 미만의 저결합 질의 75개와 0.3 이상의 고결합 질의 10개로 분류한다. 이는 메타데이터 조건과 사용자 질의가 강하게 얽혀 있는 경우(고결합)와 독립적인 경우(저결합)에 따라 사전 필터링(검색 전 조건 적용)과 사후 필터링(검색 후 조건 적용) 중 어느 계획이 우수한지 조건부 가이드라인을 도출하기 위한 통제적 분석 방법이다.

유한한 실험 표본 내에서 발생하는 측정 불확실성을

(a) VRU-Accident 수정 전후 검색 품질



(b) AI Hub 교차로 통제 주입 효과



<그림 2> 순환성 진단과 통제 주입 결과.

(a) VRU-Accident의 수정 전후 검색 품질 차이

(b) AI Hub 교차로의 정답 정보 통제 주입 효과

배제하고 결과의 통계적 유의성을 확보하기 위해 엄격한 검정 방법론을 도입한다. 영상 벤치마크 데이터의 비정규 분포 특성을 고려하여 불확실성은 비모수적 기법인 부트스트랩 95% 신뢰구간[29]으로 보고한다. 또한, 변수 간 단조 관계 분석에는 Spearman 순위상관분석[30], 구성 간 성능의 대응 비교에는 데이터의 정규성 가정을 요구하지 않는 Wilcoxon 부호순위 검정[31]을 사용한다. 특히, 112개의 방대한 검색 구성을 비교할 때 1종 오류(Type I error)가 급격히 증가하는 다중 비교 문제(Multiple Comparisons Problem)를 해결하기 위해 사전에 정의된 주요 비교쌍에는 Holm 보정[32]을 적용하여 통계적 엄밀성을 극대화하고, 사후 탐색적 비교에는 Benjamini-Hochberg 보정[33]을 통한

<표 3> 순환 작업 부하의 수정 전후 검색 품질

(nDCG@10)

데이터-검색 방식	수정 전	수정 후 엄격한 정답	수정 후 의미론적 정답
VRU-Accident / 검색 전 조건 적용	0.9736	0.3174	0.2974
VRU-Accident / 벡터 단독 검색	0.4476	0.1845	0.2649
VRU-Accident / BM25 어휘 검색	0.4495	0.0918	0.1607
지능형 관제 CCTV / BM25 어휘 검색	0.9600	0.1111	0.1667
지능형 관제 CCTV / 검색 전 조건 적용	1.0000	0.8395	0.8395


허위발견율(False Discovery Rate, FDR) 제어를 적용하여 본 연구의 실험 결과와 최종 결론에 강력한 학술적 신뢰성을 부여한다.

5.2 실험 결과 및 분석

5.2.1. 비순환 작업 부하 검증 결과 (RQ1)

그림 2와 표 3은 영상 데이터베이스 검색 평가에서 발생하는 순환성 왜곡(데이터 누수)의 실태를 진단하고, 이것이 검색 점수를 부풀리는 인과 관계를 통제 실험을 통해 입증함으로써 본 연구가 제안하는 '세 원천 소스 기반의 비순환 작업 부하'가 타당함을 증명한다.

표 3에서 수정 전의 기존 작업 부하(VRU-Accident 및 지능형 관제 CCTV)는 정답 정보나 사건 라벨이 검색 문서와 메타데이터 조건에 직접 노출되어 있어, 비정상적으로 완벽한 가까운 수준의 검색 품질(nDCG@10 0.9600-1.0000)을 기록하였다. 그러나 본 연구가 제안한 세 원천 분리 프로토콜을 적용하여 영상 픽셀, 센서 메타데이터, 사람 주석의 수집 경로를 완전히 독립시킨 비순환 평가 구조로 전환하자 검색 점수가 현실적인 수준으로 급격히 감소하였다. 이러한 큰 폭의 하락은 기존 평가 환경에 존재하던 정답 정보의 부당한 재사용(데이터 누수)이 제거되었음을 뜻하며, 검색 시스템의 실제 시각



<그림 3> 데이터베이스 계층 설계별 품질-지연 트레이드오프 분포. (a) 의미론적 정답, (b) 엄격한 정답

<표 4> 검색용 데이터별 품질-지연-저장량 비교 (벡터 단독 검색, Flat, 질의 85개)

검색용 데이터	엄격한 정답 nDCG@10	의미론적 정답 nDCG@10	설명문 대비 Δ [균집 95% 신뢰구간]	p50 지연 시간(밀리초)	float32 벡터 저장량(MB)
영상 설명문	0.063	0.181	기준	1.15	24.6
대표 이미지	0.063	0.186	+0.005 [-0.075, +0.079]	1.21	24.6
이미지·설명문 결합	0.079	0.218	+0.037 [-0.005, +0.074]	1.24	24.6
다중 이미지	0.101	0.352	+0.171 [+0.018, +0.316]	3.65	68.4
이중 색인	0.089	0.293	+0.112 [-0.004, +0.228]	4.96	93.0

장면 이해 및 필터링 능력을 잡음 없이 온전히 계측할 수 있는 평가 환경이 수립되었음을 증명한다.

그림 2(b)는 모델과 데이터를 고정된 상태에서 순환성 요인만을 주입했을 때의 인과적 점수 상승 효과와 95% 신뢰구간을 보여준다. 순수한 비순환 상태의 검색 품질(0.1810)과 비교했을 때, 메타데이터 조건에 정답 영상을 유출(정답 영상 필터)시키면 검색 성능이 1.0000으로 상승했다. 또한 검색 문서 텍스트에 정답 라벨을 재진술한 텍스트를 추가했을 때에도 0.8540으로 품질이 상승했다. 이는 시스템 내부 알고리즘의 개선 없이도 단지 평가 데이터의 유출 경로가 존재한다는 사실만으로 품질이 최대 4.7배 부풀려질 수 있음을 입증한다. 단순히 후보군 수 감소로 인한 확률적

점수 상승 효과를 배제하기 위해 동일한 선택도를 가지는 무작위 대조군 조건(1,000회 평균 nDCG@10, 0.1200)을 적용해 대조했을 경우에도 유입된 순환성 효과의 편차는 통계적으로 유의미하게 컸다.

5.2.2. 검색용 데이터 구성 평가 (RQ2)

그림 3과 표 4는 검색용 데이터 구성이 검색 품질뿐 아니라 지연 시간과 저장량까지 변화시키며, 모든 시나리오를 지배하는 단일 최적 구성은 존재하지 않음을 보여준다.

먼저, 설명문 생성용 VLM의 성능 변화를 통제 비교한 결과, 최신 모델인 Qwen3.5-9B[34]가 세 가지 데이터셋(AI Hub 교차로, MEVA, UCA/UCF-Crime) 전체에서 Qwen2.5-VL-7B-Instruct 대비 유의미한

의미론적 품질 향상(nDCG@10 기준 AI Hub +0.102, MEVA +0.168, UCA +0.054)을 기록하였다. 이에 따라 이후 데이터 구성 실험은 Qwen3.5-9B를 기본 설명문 생성 모델로 고정하여 진행하였다.

표 4는 다섯 가지 검색용 데이터 구성의 품질-비용 절충 관계를 정리하여 보고한다. 본 연구는 AI Hub 교차로 3,000개 클립 코퍼스와 85개 질의 세트를 Qwen3-VL-Embedding-2B 멀티모달 벡터 공간에 매핑한다. 그리고 벡터 단독 검색과 Flat 정확 전수 검색으로 설정을 통제하여 데이터 구성만을 독립 변인으로 변화시키며 평가하였다. 두 실험 간 임베딩 모델의 차이로 인해, 본 결과의 절대 nDCG@10 수치는 앞선 VLM 성능 비교 결과와 직접 대비하지 않고 개별 실험 내에서만 상대적으로 해석한다. 또한, 검색 품질의 변화량을 정량화하기 위해 기준선인 영상 설명문 대비 각 구성의 nDCG@10 점수 차이를 효과량 ' Δ '로 정의하였다.

기준선 대비 대표 이미지 구성은 저장량(24.6MB)이 동일한 조건에서 엄격한 정답(0.063)과 의미론적 정답(0.186) 모두 뚜렷한 품질 차이를 보이지 않았다(설명문 대비 $\Delta = +0.005$ [$-0.075, +0.079$]). 이미지와 설명문을 동일 벡터 공간으로 융합한 이미지-설명문 결합 구성의 경우, 추가적인 저장량 증가 없이 의미론적 정답의 점 추정치를 0.181에서 0.218로 상승시켰으나, 효과량 Δ 의 95% 신뢰구간($+0.037$ [$-0.005, +0.074$])이 0을 포함하여 기준선 대비 확실한 성능 향상을 통계적으로 보장하지는 못하므로 추가적인 저장 자원 요구량 증가 없이 적용해 볼 수 있는 대안적 후보로 해석한다.

가장 극적인 품질 개선은 다중 벡터 기반의 정보 확장 구성에서 확인되었다. 다중 이미지 구성은 의미론적 정답 nDCG@10 기준 0.352의 가장 높은 점 추정치를 기록하며 기준선 대비 유의미한 성능 이득($\Delta = +0.171$ [$+0.018, +0.316$])을 달성하였다. 그러나 이 이득은 벡터 저장량이 24.6MB에서 68.4MB로 약 2.8배 늘고 p50 지연 시간이 1.15밀리초에서 3.65밀리초로 3배 이상 증가하는 물리적

비용을 동반한다. 또한, 저장 방식 비교군 전체를 대상으로 한 Benjamini-Hochberg 보정 p-value가 0.112로 도출되었으므로, 해당 우위를 통계적 제약이 없는 보편적 효과로 단정 짓기는 어렵다. 텍스트와 다중 이미지 색인을 결합하여 상수 $k=60$ 의 RRF로 처리하는 이중 색인 구성 역시 의미론적 정답 0.293 ($\Delta = +0.112$ [$-0.004, +0.228$])의 개선 효과를 보였으나, 저장량 93.0MB와 p50 지연 시간 4.96밀리초를 요구하여 다섯 구성 중 가장 높은 물리적 비용이 발생하였다.

그림 3은 4.2장에서 정의한 검색용 데이터 및 검색 계획의 16개 조합과 7개 물리 색인 설정의 곱으로 도출된 총 112개 조합 구성의 엄격한 및 의미론적 정답 품질과 p50 지연 시간의 관계 분포를 보여준다. 이는 품질 극대화와 물리적 비용 최소화를 동시에 충족하는 파레토(Pareto) 최적 경계를 함께 제시한다. 대표적인 사례로, 다중 이미지와 Flat 물리 색인을 고정한 상태에서도 메타데이터 조건의 처리 목적에 따라 평가가 극단적으로 엇갈렸다. 엄격한 정답 기준에서는 검색 전 조건 적용이 벡터 단독 검색보다 nDCG@10을 0.161만큼 향상시켰으나, 의미론적 정답 기준에서는 오히려 성능을 0.093만큼 하락시켰다. 결과적으로 RQ2 하에서 최적의 검색용 데이터를 선택하는 의사결정 기준은 단일한 최고 성능 수치로 고정될 수 없다. 따라서 서비스가 지향하는 정답 기준(엄격한 정답 및 의미론적 정답)을 먼저 확립하고, 인프라가 허용하는 지연 시간과 저장량 임계치 범위 내에서 파레토 후보군 중 최적의 구성을 조건부로 선택해야 한다.

5.2.3. 검색 계획 평가 (RQ3)

검색 계획(벡터 단독, 검색 전/후 조건 적용, 혼합 검색)의 영향력을 규명하기 위해, 실험은 Qwen2.5-VL-7B-Instruct 모델 기반의 3,000개 영상 설명문 코퍼스, BGE-M3 임베딩, 그리고 Flat 정확 전수 검색 구조와 85개의 질의 세트를 통제 변인으로 설정하여 평가를 진행하였다.

<표 5> 질의 구성 방식 및 조건-의미 결합도에 따른 검색 전 조건 적용의 효과(Δ) - 의미론적 정답 기준

분석 분류 및 세부 항목	$\Delta nDCG@10$	95% 신뢰구간 (단위)	주요 결과 판정
질의 표본 기준			
최초 표본 (32질의)	-0.0745	[-0.136, -0.014] (질의)	벡터 단독 검색이 유의하게 우세
확장 표본 (53질의)	+0.0197	[-0.008, +0.050] (질의)	두 방식 간 성능 차이 무의미
통합 표본 (85질의)	-0.0158	[-0.047, +0.015] (질의)	두 방식 간 성능 차이 무의미
결합도 기준			
저결합 $V < 0.3$ (23쌍)	-0.0357	[-0.094, +0.010] (쌍)	두 방식 간 성능 차이 무의미
고결합 $V \geq 0.3$ (2쌍)	+0.1335	[+0.078, +0.356] (쌍)	사전 필터 적용이 유의하게 우세

효과량 Δ 는 검색 전 조건 적용과 벡터 단독 검색의 $nDCG@10$ 점수 차이로 정의하며, 표 5와 표 6에 정답 기준 및 질의 특성별 효과량 상세 결과를 제시한다. 메타데이터 조건이 필수 제약으로 작동하는 엄격한 정답 기준에서는 검색 전 조건 적용(0.157)이 벡터 단독 검색(0.059)을 크게 앞서 유의한 성능 향상을 보였다($\Delta = +0.0983$, [95% 신뢰구간: +0.068, +0.133]). 그러나 이는 조건 충족이 정답에 강제되어 발생한 자명한 결과이다. 반면 메타데이터가 보조 관심 단서로 작동하는 의미론적 정답 기준에서는 조기 누락 위험으로 인해 벡터 단독 검색(0.170)이 가장 높은 성능을 보였고, 검색 전 조건 적용(0.154, $\Delta = -0.0158$, [95% 신뢰구간: -0.047, +0.015]), 검색 후 조건 적용(0.150), 혼합 검색(0.133) 순으로 그 뒤를 이었다.

표 5는 이 효과가 질의 표본과 결합도에 따라 어떻게 달라지는지 정리한다. 질의 표본은 세 가지다. 최초 표본은 연구 초기에 수작업으로 구성한 32질의, 확장 표본은 전체 조건-의미 조합에 최소 양성 5개

<표 6> AI Hub 교차로와 UCA의 메타데이터 조건 적용 효과 일치성 비교

검증 항목 (가설)	AI Hub 결과	UCA 결과
필수 제약의 효과 (엄격한 정답 Δ)	+0.0983 (향상)	+0.1501 (향상)
관심 단서의 효과 (저결합 의미론적 Δ)	-0.0357 (하락)	-0.0485 (하락)
검색 전 조건 적용이 불리한 질의 비율	30.6% (26/85)	52.7% (68/129)
고결합 시 추가 이득 여부	+0.1335 > -0.0357	-0.0558 < -0.0485

규칙을 적용해 추가한 53질의, 통합 표본은 두 표본을 합친 85질의다. 관심 단서의 Δ 는 최초 표본에서 -0.0745, 확장 표본에서 +0.0197, 통합 표본에서 -0.0158로 부호와 크기가 엇갈려, 필터 적용의 이득이 질의 표본 선택에 민감하게 반응함을 보여준다.

결합도는 메타데이터 조건 충족 여부와 장면 의미 관련성이 함께 나타나는 정도이다. 조건과 의미가 독립적인 저결합($V < 0.3$) 조건에서는 검색 전 조건 적용이 성능 저하 경향을 보였으나($\Delta = -0.0357$), 조건과 의미가 연관된 고결합($V \geq 0.3$) 조건에서는 검색 전 조건 적용이 유의미한 추가 성능 이득을 제공했다($\Delta = +0.1335$).

표 6은 이러한 경향이 외부 데이터셋 UCA/UCF-Crime의 129질의 분석에서도 재현됨을 보여준다. UCA 전체 135질의에서 정상 영상 조건 5개와 조건-정답이 겹친 퇴화 질의 1개를 제외해 129질을 분석했다. UCA에서 필수 제약의 향상($\Delta = +0.1501$)과 관심 단서 적용 시의 의미 손실 경향($\Delta = -0.0485$, 신뢰구간이 0을 포함)은 AI Hub 교차로 결과와 일치했다. 하지만 강한 결합 조건의 추가 이득은 재현되지 않았다($\Delta = -0.0558$). UCA에는 독립 센서 채널이 없고 결합도 $V \geq 0.3$ 인 질의도 135개 중 3개뿐이어서 고결합 우위의 외부 대조는 탐색적 근거로 제한한다.

이 결과를 종합하면, 데이터베이스 계층을 설계할 때 메타데이터 조건을 하나의 확일적 필터로 처리해서는 안 된다. 시스템이 강제해야 하는 필수 제약에는 성능 저하를 막기 위해 검색 전 조건 적용을 채택하는 것이 유리하다. 그러나 의미 검색을 보강하려는 관심 단서에서는 무분별한 사전 필터링이 의미상 관련된 클립을 초기에 탈락시킨다. 따라서 관심 단서가 결합된 질의에서는 벡터 단독 검색을 기본으로 두거나, 사전 필터링이 의미론적 정답 기준에서 관련 영상을 누락시킬 가능성을 사후 검증한 뒤 도입해야 한다.

5.2.4. 검색 신호와 순위 융합 평가 (RQ4)

네 가지 검색 신호(메타데이터 단독, BM25 어휘 검색, 벡터 단독 검색, BM25-벡터 역순위 융합)의 통제 비교를 바탕으로, 순환성이 배제된 평가 환경에서 어휘 신호와 그 재조합이 독립적인 검색 이득을 제공하는지 규명한다. 평가는 nDCG@10을 지표로 삼아 엄격한 정답과 의미론적 정답 두 기준으로 채점했다.

기준선인 메타데이터 단독은 엄격한 정답 0.218, 의미론적 정답 0.217을 기록했다. 이는 조건을 충족한 영상을 단순 ID 순으로 반환하므로, 검색기 자체의 순위화 능력보다 메타데이터 조건과 정답 의미 간의 물리적 결합도를 반영한다. 한편, BM25 어휘 검색은 엄격한 정답 0.017, 의미론적 정답 0.050에 그친 반면, 벡터 단독 검색은 각각 0.059와 0.170을 기록했다. 의미론적 정답 기준에서 두 검색 방식 간의 큰 성능 격차는 현재의 어휘 신호 변별력이 벡터 신호에 비해 매우 취약함을 의미한다.

순위 융합의 독립적인 기여 또한 검색 전 조건 적용 상태를 거친 부분집합을 바탕으로 검증했다. 벡터 단독 검색의 의미론적 정답 점수는 0.154였다. 여기에 BM25 어휘 검색 순위를 RRF로 결합한 혼합 검색은 0.133으로 오히려 성능이 하락했다. 이는 입력 후보군과 검색 전 조건 적용 상태를 동일하게

<표 7> 실제 시공간 군집 조건과 무작위 대조 조건 간의 근사 색인 재현율 왜곡 효과(Δ) 비교

조건 적용 방식	시내도로 (n=29쌍)	교차로 (n=25쌍)
전역 HNSW 상위 40개 검색 후 적용	+0.611 [0.554, 0.661]	+0.289 [0.219, 0.359]
IVF 탐색 중 적용 (nprobe=8)	+0.627 [0.550, 0.699]	+0.217 [0.144, 0.294]
IVF 탐색 중 적용 (nprobe=32)	+0.498 [0.407, 0.585]	+0.116 [0.072, 0.159]
조건별 부분집합 HNSW	+0.017 [0.012, 0.023]	+0.004 [0.002, 0.006]
조건별 부분집합 Flat	$\Delta=0$ (검정 불능)	$\Delta=0$ (검정 불능)

통제하더라도 변별력이 약한 BM25 신호가 혼합되면서 검색 순위를 방해했음을 뜻한다. 따라서 순위 융합에 따른 개선 효과는 관찰되지 않았다.

지식그래프 재조합 역시 동일한 결과를 보였다. 센서 조건과 설명문 개체로 구축한 지식그래프에서 특정 개체를 포함한 문서가 정답일 확률이 전체 평균 대비 향상되는 정도를 나타내는 리프트(Lift)는 중앙값 0.002로, 유의미한 검색 신호를 제공하지 못했다. 이 지식그래프로 순위를 매긴 엄격한 정답 nDCG@10도 0.176에 그쳐 메타데이터 단독(0.218)보다 낮았다. 결과적으로 RQ4는 BM25 어휘 검색, 순위 융합, 지식그래프 재조합 모두 비슷한 평가에서 독립적인 성능 이득을 보이지 못했다고 결론 내린다. 따라서 실제 운영에서는 각 검색 신호의 품질을 사전에 검증해야 하며, 신뢰성이 확인되지 않은 약한 신호와의 무분별한 융합은 지양해야 한다.

5.2.5. 물리 색인과 배포 평가 (RQ5)

표 7은 실제 환경에서 수집된 장소-시간 등의 메타데이터 조건이 근사 색인(ANN)의 검색 재현율에 미치는 성능 영향을 평가하기 위해 구성한 무작위 대조군과의 구체적인 재현율 격차 Δ 를 제시한다.

<표 8> pgvector 반복 스캔 적용 시 메타데이터 조건별 검색 품질 및 지연 시간 비교

메타데이터 조건 (선택도)	기본 검색: 재현율 / 부족률	반복 스캔: 재현율 / 부족률 / p50
장소=BC2000801 (0.086)	0.121 / 87.9%	0.658 / 5.8% / 19.0 ms
장소=중동사거리 (0.049)	0.034 / 96.6%	0.302 / 50.8% / 29.5 ms
시각=06 (0.183)	0.310 / 75.0%	0.984 / 0.0% / 1.01 ms
시각=06-18 (0.774)	0.876 / 14.2%	0.994 / 0.0% / 0.44 ms

<표 9> 상용 벡터 데이터베이스(Milvus 및 Weaviate)에서의 조건 적용 방식에 따른 재현율 차이 비교

엔진과 실행 방식	데이터	n쌍	재현율 Δ (무작위-실측) [95% 신뢰구간]	판정
Weaviate 탐색 확대	시내도로	24	+0.0098 [0.0049, 0.0159]	Holm 보정 뒤 유의
Milvus 그래프 탐색	교차로	18	+0.0028 [0.0009, 0.0049]	Holm 보정 뒤 유의
Milvus 그래프 탐색	시내도로	6	+0.0140 [0.0079, 0.0220]	방향만 일치
Weaviate 탐색 확대	교차로	22	+0.0006 [0.0000, 0.0015]	방향만 일치, 효과는 작음
Milvus 전수 검색 전환	시내도로	18	+0.0006 [0.0004, 0.0008]	전수 검색에서 손실 제거
Milvus 전수 검색 전환	교차로	4	재현율 ≥ 0.9986 , $\Delta \leq +0.0014$	관측값만 보고 (n<5)
Weaviate ACORN	교차로	22	-0.0181 [-0.046, +0.003]	부호 역전 경향, 0 포함

실제 데이터 분포에 따른 색인 성능 왜곡 효과를 분리하기 위해 실제 수집된 메타데이터 조건과 동일한 선택도를 부여한 무작위 대조 조건 간의 짝 비교를 시내도로 및 교차로 데이터셋 환경에서 수행했다. 메타데이터 조건 적용 방식은 전역 HNSW 색인에서 전역 검색 후 필터링을 수행하는 방식, IVF 탐색 중 필터링을 수행하는 방식, 그리고 조건별 부분집합만을 대상으로 HNSW 및 Flat 색인에서 검색하는 조건별 부분집합 검색 방식으로 분류하여 비교했다.

표 7의 분석 결과에 따르면, 전역 HNSW 및 IVF 색인을 사용하는 모든 필터링 방식에서 실제 시공간 군집 조건에서 최대 0.627의 심각한 재현율 손실이 관찰되었다. 대조군의 변동 폭은 최대 0.047에 그친 반면 실제 환경에서 나타난 성능 격차는 컸다. 이는 시공간적으로 조밀하게 군집된 데이터 분포가 전역 그래프 탐색을 방해하여 검색 누락을 유발하는 결정적 요인임을 보여준다. 결과적으로 단순 선택도만 일치시킨 무작위 조건은 실제 시공간 조건의 탐색 난이도를 반영하는 데 한계가 있어 실제 검색 손실을 크게 과소평가한다.

이러한 재현율 결손을 복구하기 위한 실행 경로별 성능 개선과 연산 비용은 메타데이터 조건의 종류에 따라 큰 차이를 보였다. 표 8의 pgvector 환경 반복 스캔 평가 결과, 시간 조건은 지연 시간의 큰 상승 없이 재현율을 98% 이상 회복했다. 그러나 군집도가 높은 장소 조건은 재현율 복구 범위가 30~65% 수준에 머물렀고, 지연 시간은 최대 29.51밀리초로 급증하여 그래프 탐색 범위의 단순한 확대가 지닌 한계를 입증했다. 또한 표 9에 제시된 Milvus와 Weaviate[35] 환경 평가 결과에서도 그래프 탐색 확대 시 유의한 재현율 손실(최대 +0.0098)을 보였다. 조건에 의해 필터링되는 비율이 약 92.3% 이상이거나 조건을 만족하는 벡터가 40,000개 미만일 때 시스템 실행 경로가 자동으로 전수 검색으로 전환되며, 이로 인해 재현율 결손은 0.0014 이하로 대폭 감축되었다.

이상의 결과를 종합하여 수립한 조건부 물리 색인 배포 기준은 다음과 같다. 표 10의 조건 개입이 없는 기본 물리 색인별 성능-비용 프로파일을 기준선으로 삼고, 전역 색인의 재현율이 목표치인 0.95를 충족하지 못할 경우 조건별 부분 색인(부분집합

<표 10> 조건이 없는 두 실측 코퍼스의 물리 색인 품질 및 비용 비교

코퍼스	구성	재현율@10	p50 / p95(ms)	구축(초)	크기(MB)
시내도로 131,000개	Flat	1.0000	13.43 / 14.37	0.11	268.0
	HNSW(M=16)	0.9970	0.041 / 0.055	34.8	287.0
	HNSW(M=32)	0.9970	0.044 / 0.062	36.5	304.0
	IVF-Flat(nprobe=8)	0.9940	0.113 / 0.144	13.9	271.0
	IVF-PQ(m=64, nprobe=8)	0.4810	0.135 / 0.158	26.1	12.0
	IVF-PQ(m=32, nprobe=8)	0.3340	0.129 / 0.153	25.9	8.0
AI Hub 교차로 142,000개	Flat	1.0000	14.18 / 15.34	0.12	290.8
	HNSW(M=16)	0.9994	0.044 / 0.061	44.3	311.3
	HNSW(M=32)	0.9992	0.047 / 0.069	47.1	329.5
	IVF-Flat(nprobe=8)	0.9971	0.116 / 0.165	15.1	294.1
	IVF-PQ(m=64, nprobe=8)	0.4938	0.134 / 0.172	27.9	12.9
	IVF-PQ(m=32, nprobe=8)	0.3489	0.131 / 0.157	27.1	8.3

HNSW)이나 전수 검색을 활성화하여 검색 품질을 복구한다. 조건별 부분 색인의 구축 비용 대비 질의 지연 단축 효과를 고려할 때, 부분 색인의 배포는 다음 색인 갱신 시점까지의 예상 질의 수가 해당 조건의 선택도별 손익분기점을 초과하는 경우에만 수행한다. 결과적으로 RQ5의 핵심은 실제 메타데이터 조건의 시공간적 군집 구조를 반영한 평가의 필요성을 입증하고, 이에 기초한 하이브리드 색인 관리 및 배포 절차를 확립한 데 있다.

5.2.6. 답변 효과 검증 실험 결과 (RQ6)

답변 효과 검증 실험에서는 검색된 증거의 품질이 대형 언어 및 멀티모달 모델의 최종 답변 정확도에 미치는 영향을 평가했다. 설명문 증거의 관련성 평가 결과, 증거가 없는 기본 상태(31%)에 비해 무관한 설명문 제공 시 53%, 벡터 검색 설명문 제공 시 67%, 대상 설명문을 직접 제공할 때 최대 75% 순으로 모델의 정확도가 단계적으로 향상되어 관련 증거의 회수가 답변 품질 개선의 핵심 요인임이 증명되었다. 다만 벡터 검색에 메타데이터 조건을 결합한 추가 성능 향상 폭은 2%포인트 미만으로 제한적이었다. 또한 가시성 차이가 있는 다각도 시점 평가 결과, 시점이 잘 확보된 단일 영상을 제공했을 때 정확도가

최대 15.2%포인트 향상된 반면 두 시점을 동시에 제공하는 조치는 추가 이득이 관찰되지 않았다. 이는 단순한 증거의 양적 확대보다 대상 장면을 명확히 보여주는 핵심 시점을 선별하여 전달하는 설계가 유효함을 보여준다.

반면 근사 색인의 재현율 차이가 최종 답변까지 전파되는지 검증하는 실험은 판정에 필요한 증거 적중 표본의 부족으로 인해 탐색적 결과 수준에 머물렀다. 벡터 색인 구조별 증거 회수율 차이가 5% 이내로 미미하여 답변 정확도에 미치는 영향을 유의미하게 대조하기에 제한이 있었다. 정답 증거의 적중 횟수 또한 부족하여 대규모 생성을 통한 추가적인 정량 분석이 요구된다.

결과를 종합하면 RQ6은 관련성 높은 설명문 검색과 가시성이 우수한 카메라 시점 선택이 모델 답변을 직접적으로 개선함을 입증한다. 다만 색인 재현율 오차가 최종 생성 답변까지 미치는 세부 파급 효과는 향후 데이터 편향을 배제하고 증거 적중 표본을 추가로 확보하여 보완 검증을 수행해야 한다.

5.3. 교훈 및 한계

본 평가 결과는 데이터 누수 차단을 위한 비순환 평가의 필수성, 검색 품질·속도·비용 간 상충 관계,

그리고 검색 개선이 VLM 답변으로 자동 전파되지 않는다는 핵심 교훈을 제공한다. 따라서 데이터베이스 계층은 실제 현장 조건에서 성능·비용의 최적 균형 조합을 찾고, 검색 결과가 VLM 답변으로 전파되는지를 단계별로 검증해야 한다. 다만 본 연구는 프롬프트의 과제 범주 의존성, 고결합 질의 및 적중 표본의 소수성, 실시간 영상 유입과 동시 부하를 반영하는 동적 환경 모사의 한계를 지닌다.

6. 결론 및 향후 연구

본 연구는 멀티모달 영상 RAG 파이프라인에서 데이터베이스 계층의 물리 설계를 공정하게 비교·평가하기 위한 비순환 평가 작업 부하를 구축하였다. 메타데이터 조건은 센서 기록, 검색 문서는 영상 픽셀 기반 VLM 설명문, 검색 정답 집합은 사람 주석에서 각각 독립 구성하여 데이터 생성 경로를 완전히 분리하였다. 나아가 정답 기반 조건과 라벨 재진술 문장을 의도적으로 주입한 통제 실험을 통해 정답 정보의 재사용(데이터 누수)이 검색 점수를 왜곡하여 부풀리는 정도를 정량 입증하였다.

비순환 작업 부하 체계를 바탕으로 저장 방식, 필터 적용 방식, 검색 신호, 물리 색인과 배포 방식을 비교했다. 그 결과, 데이터베이스 계층의 검색 성능 최적화 구성은 정답 기준과 데이터 분포 및 자원 제약에 따라 달라졌다. 다중 이미지는 검색 품질의 가장 높은 점 추정치를 제공했지만 저장량과 지연 시간이 증가했다. 메타데이터 조건은 필수 제약과 관심 단서에서 서로 다른 효과를 보였다. 실측 조건의 시공간적 군집은 공유 근사 색인의 재현을 손실을 확대했으며, 동일 선택도의 무작위 조건만으로는 이 현상을 재현하기 어려웠다. 관련 설명문과 가시성이 높은 카메라 시점은 VLM 답변 방향과 연결되었지만, 근사 색인의 검색 차이가 답변 품질로 전파되는 효과는 현재 표본에서 확립되지 않았다.

본 연구의 실험 결과는 데이터베이스 계층을 설계하는

순서를 제시한다. 먼저 평가 요소의 생성 경로를 검사하여 순환성을 차단하고, 메타데이터 조건을 필수 제약으로 불지 관심 단서로 불지에 따라 검색 정답 기준을 확정해야 한다. 이후 실측 조건에서 검색 품질·지연 시간·저장량·구축 비용을 함께 측정하여 파레토 구성을 선택하고, 선택한 검색 구성이 최종 답변에 미치는 효과를 증거 회수·VLM 인식·답변 변화의 단계로 나누어 검증해야 한다.

향후 연구에서는 고결합 조건·의미 쌍과 정답 증거 적중 표본을 확대하여 현재의 탐색적 결과를 재검증할 예정이다. 또한 실시간 영상 유입과 메타데이터 변경, 동시 질의를 포함하는 동적 작업 부하를 구축하고, 조건별 부분 색인의 생성·갱신·폐기를 자동화하는 관리 정책을 평가할 계획이다. 여러 VLM과 벡터 데이터베이스 엔진을 대상으로 검색부터 답변 생성까지의 종단 지연과 비용을 측정하여 본 연구에서 제시한 설계 교훈의 적용 범위를 확장하고자 한다.

참고 문헌

- [1] S. Jeong et al., "VideoRAG: Retrieval-Augmented Generation over Video Corpus," Findings of the Assoc. for Computational Linguistics: ACL 25, 2025, pp. 21278-21298; doi:10.18653/v1/2025.findings-acl.1096.
- [2] J.J. Pan, J. Wang, and G. Li, "Survey of Vector Database Management Systems," VLDB J., vol. 33, no. 5, 2024, pp. 1591-1615; doi:10.1007/s00778-024-00864-x.
- [3] A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision," Proc. 38th Int'l Conf. Machine Learning (ICML 21), PMLR, vol. 139, 2021, pp. 8748-8763.
- [4] Q. Zhang et al., "VBASE: Unifying Online Vector Similarity Search and Relational Queries via Relaxed Monotonicity," Proc. 17th USENIX Symp. Operating Systems Design and Implementation (OSDI 23), 2023, pp. 377-395.

- [5] L. Patel et al., "ACORN: Performant and Predicate-Agnostic Search Over Vector Embeddings and Structured Data," *Proc. ACM Management of Data*, vol. 2, no. 3, article 120, 2024, pp. 1-27; doi:10.1145/3654923.
- [6] Y. Kim et al., "VRU-Accident: A Vision-Language Benchmark for Video Question Answering and Dense Captioning for Accident Scene Understanding," *Proc. IEEE/CVF Int'l Conf. Computer Vision Workshops (ICCVW 25)*, 2025, pp. 772-782; doi:10.1109/ICCVW69036.2025.00085.
- [7] 한국지능정보사회진흥원, "지능형 관제 서비스 CCTV 영상 데이터," AI Hub, 2024. <https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=71850>, viewed on July 20, 2026.
- [8] D.G. Grimm et al., "The Evaluation of Tools Used to Predict the Impact of Missense Variants Is Hindered by Two Types of Circularity," *Human Mutation*, vol. 36, no. 5, 2015, pp. 513-523; doi:10.1002/humu.22768.
- [9] S. Kaufman et al., "Leakage in Data Mining: Formulation, Detection, and Avoidance," *ACM Trans. Knowledge Discovery from Data*, vol. 6, no. 4, article 15, 2012, pp. 1-21; doi:10.1145/2382577.2382579.
- [10] K. Järvelin and J. Kekäläinen, "Cumulated Gain-Based Evaluation of IR Techniques," *ACM Trans. Information Systems*, vol. 20, no. 4, 2002, pp. 422-446; doi:10.1145/582415.582418.
- [11] Y. Chronis et al., "Filtered Vector Search: State-of-the-art and Research Opportunities," *Proc. VLDB Endowment*, vol. 18, no. 12, 2025, pp. 5488-5492; doi:10.14778/3750601.3750700.
- [12] pgvector, "pgvector v0.8.4," software release, 30 June 2026; <https://github.com/pgvector/pgvector/tree/v0.8.4>, viewed on July 20, 2026.
- [13] J. Wang et al., "Milvus: A Purpose-Built Vector Data Management System," *Proc. 2021 Int'l Conf. Management of Data (SIGMOD 21)*, 2021, pp. 2614-2627; doi:10.1145/3448016.3457550.
- [14] T. Yuan et al., "Towards Surveillance Video-and-Language Understanding: New Dataset, Baselines, and Challenges," *Proc. IEEE/CVF Conf. Computer Vision and Pattern Recognition (CVPR 24)*, 2024, pp. 22052-22061; doi:10.1109/CVPR52733.2024.02082.
- [15] C. Kittivorawong et al., "Spatialyze: A Geospatial Video Analytics System with Spatial-Aware Optimizations," *Proc. VLDB Endowment*, vol. 17, no. 9, 2024, pp. 2136-2148; doi:10.14778/3665844.3665846.
- [16] S. Robertson and H. Zaragoza, "The Probabilistic Relevance Framework: BM25 and Beyond," *Foundations and Trends in Information Retrieval*, vol. 3, no. 4, 2009, pp. 333-389; doi:10.1561/15000000019.
- [17] G.V. Cormack et al., "Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods," *Proc. 32nd Int'l ACM SIGIR Conf. Research and Development in Information Retrieval (SIGIR 09)*, 2009, pp. 758-759; doi:10.1145/1571941.1572114.
- [18] Y.A. Malkov and D.A. Yashunin, "Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs," *IEEE Trans. Pattern Analysis and Machine Intelligence*, vol. 42, no. 4, 2020, pp. 824-836; doi:10.1109/TPAMI.2018.2889473.
- [19] 한국지능정보사회진흥원, "교차로 신호 체계, 보행자, 차량 이동 복합 데이터," AI Hub, 2021. <https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=522>, viewed on July 20, 2026.
- [20] K. Corona et al., "MEVA: A Large-Scale Multiview, Multimodal Video Dataset for Activity

- Detection," Proc. IEEE/CVF Winter Conf. Applications of Computer Vision (WACV 21), 2021, pp. 1060-1068; doi:10.1109/WACV48630.2021.00110.
- [21] 한국지능정보사회진흥원, "교통문제 해결을 위한 CCTV 교통 영상(시내도로)," AI Hub, 2020. <https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=165>, viewed on July 20, 2026.
- [22] F. Bastani et al., "MIRIS: Fast Object Track Queries in Video," Proc. 2020 ACM SIGMOD Int'l Conf. Management of Data (SIGMOD 20), 2020, pp. 1907-1921; doi:10.1145/3318464.3389692.
- [23] 한국지능정보사회진흥원, "다각도 CCTV 생활안전 데이터," AI Hub, 2025. <https://www.aihub.or.kr/aihubdata/data/view.do?dataSetSn=71953>, viewed on July 20, 2026.
- [24] S. Bai et al., "Qwen2.5-VL Technical Report," arXiv preprint arXiv:2502.13923, 2025; doi:10.48550/arXiv.2502.13923.
- [25] M. Douze et al., "The Faiss Library," arXiv preprint arXiv:2401.08281, 2024.
- [26] M. Li et al., "Qwen3-VL-Embedding and Qwen3-VL-Reranker: A Unified Framework for State-of-the-Art Multimodal Retrieval and Ranking," arXiv preprint arXiv:2601.04720, 2026; doi:10.48550/arXiv.2601.04720.
- [27] Beijing Academy of Artificial Intelligence, "BGE-M3," Hugging Face model card, 2024; <https://huggingface.co/BAAI/bge-m3>.
- [28] H. Cramér, *Mathematical Methods of Statistics*, Princeton University Press, 1946, p. 282.
- [29] B. Efron, "Bootstrap Methods: Another Look at the Jackknife," *The Annals of Statistics*, vol. 7, no. 1, 1979, pp. 1-26; doi:10.1214/aos/1176344552.
- [30] C. Spearman, "The Proof and Measurement of Association between Two Things," *American J. Psychology*, vol. 15, no. 1, 1904, pp. 72-101; doi:10.2307/1412159.
- [31] F. Wilcoxon, "Individual Comparisons by Ranking Methods," *Biometrics Bulletin*, vol. 1, no. 6, 1945, pp. 80-83; doi:10.2307/3001968.
- [32] S. Holm, "A Simple Sequentially Rejective Multiple Test Procedure," *Scandinavian J. Statistics*, vol. 6, no. 2, 1979, pp. 65-70; doi:10.2307/4615733.
- [33] Y. Benjamini and Y. Hochberg, "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing," *J. Royal Statistical Society: Series B (Methodological)*, vol. 57, no. 1, 1995, pp. 289-300; doi:10.1111/j.2517-6161.1995.tb02031.x.
- [34] Qwen, "Qwen3.5-9B," Hugging Face model card, 2026; <https://huggingface.co/Qwen/Qwen3.5-9B>.
- [35] Weaviate, "Weaviate v1.35.3," software release, 15 Jan. 2026; <https://github.com/weaviate/weaviate/releases/tag/v1.35>.