

- 심사위원 1에 대한 응답 -

저자 노트: 심사 의견에 감사드립니다. 아래와 같이 심사평의 각 문장에 대해 답변하고, 해당 내용을 수정 원고에 반영하였습니다. 답변과 반영 위치는 최종 제출용 대응서에서 파란색으로 표기하였습니다.

심사위원 1의 지적 사항

서술적 심사평

본 연구는 대규모 영상 RAG 구축에 있어서 핵심적인 기술인 벡터 DB 기술(검색, 색인 등)의 한계점인 '평가 순환성'을 차단하는 비순환 평가 체계를 수립하고, 저장부터 배포까지 비용을 다차원적으로 고려하여 측정하고 분석하는 방법을 제안하고 있다.

⇒ 본 연구의 핵심 범위와 평가 순환성 차단의 의미를 정확히 이해해 주셔서 감사드립니다. 개정 원고에서는 평가 타당성 확보, 설계 대안 비교, 답변 전파 진단의 의존 순서를 서론, 그림 1, 4.1-4.3 절과 RQ1-RQ6에 일관되게 반영하였습니다.

반영 위치: 1장 서론, 그림 1, 4.1-4.3 절, 5장 연구 질문.

이를 실제 시스템에서 확인하는 부분에서 큰 의미가 있는 논문이라고 할 수 있다.

⇒ 실증적 의의를 긍정적으로 평가해 주셔서 감사드립니다. 개정 원고에서는 Faiss, pgvector, Milvus와 Weaviate의 검색·색인 실행 경로를 비교하고, 실측 코퍼스와 메타데이터 조건에서 확인한 품질·비용 결과 및 적용 범위를 함께 제시하였습니다.

반영 위치: 5.1.2-5.1.3 절, 5.2.5 절, 표 6-9.

세부 수정 의견

1. 다만 전체적으로 논문의 고유한 컨트리뷰션이 더 잘 드러나도록 방법론 부분을 명확히 할 필요가 있다.

⇒ 지적해 주신 내용에 따라 본 연구의 기여를 세 단계로 재구성하였습니다. 첫째, 직접적인 정답 정보 재사용을 차단하고 통제 주입으로 검색 지표의 왜곡 정도를 측정합니다. 둘째, 같은 평가 원칙 아래 벡터 데이터베이스 계층의 다섯 설계 축을 비교합니다. 셋째, 관련 클립 회수·검색 문맥 인식·과제 편향 통제를 통해 검색 결과의 답변 전파 범위를 진단합니다. 이 세 단계를 서론의 공헌과 4장의 방법론 구조에 동일하게 반영하였습니다.

반영 위치: 국·영문 초록, 1장 서론의 공헌, 4.1–4.3 절, 6장 결론.

2. 논문을 통해 제시하고자 하는 방법이 새로운 알고리즘인지, method 인지, 아키텍처인지 수정보완이 필요하다.

⇒ 본 연구의 제안물은 새로운 검색 알고리즘이나 시스템 아키텍처가 아니라, 평가 타당성 확보에서 설계 대안 비교와 답변 전파 진단으로 이어지는 단계적 평가 방법론임을 명확히 하였습니다. 방법론적 기여는 비순환 평가 작업 부하의 구성·검사, 다섯 설계 축의 공통 비교, 세 단계 답변 전파 진단을 하나의 평가 흐름으로 연결하는 데 있습니다.

반영 위치: 국·영문 초록, 1장 서론, 4장 방법론, 6장 결론.

3. 또한, RQ6에서 기술이 되어있듯이 검색된 증거의 품질이 대형 언어 및 멀티모달 모델의 최종 답변에 얼마나 영향을 미쳤는지에 대해서는 유의한 결과를 확인하지 못했는데, 이에 대한 원인 분석이 5.3 절에 조금 더 추가된다면 논문의 퀄리티가 높아질 것 같다.

⇒ RQ6의 원인 분석을 관련 클립 회수, 검색 문맥 인식, 과제 편향 통제의 세 단계로 보강하였습니다. 관련 클립 회수 단계에서는 시험한 색인들이 답변 모델에 전달되는 과제 관련 상위 결과를 사전 기준만큼 다르게 만들지 못했음을 확인하였습니다. 별도의 검색 문맥 조작 실험에서는 관련 설명문과 사건이 잘 보이는 카메라 시점에 답변 모델이 반응할 수 있음을 확인하였습니다. 또한 무관 설명문만으로도 정확도가 약 22% 포인트 상승한 현상을 응답 분포와 문항 범주별로 분석하여 과제 편향의 개입 가능성을 구분하였습니다. 이에 따라 최종 답변 차이가 확립되지 않은 직접적인 원인을 답변 모델의 문맥 인식력 부족이 아니라 과제 관련 상위 검색 결과 차이의 미형성으로 설명하였습니다.

반영 위치: 5.1.3 절, 5.2.6 절, 표 10, 5.3 절, 6장 결론.

- 심사위원 2 에 대한 응답 -

저자 노트: 심사 의견에 감사드립니다. 지적해 주신 수치 불일치, 계산 기준, 분석 단위, RQ6 재현 정보, 설명문 생성 모델의 역할과 조판 문제를 문장별로 검토하여 아래와 같이 수정하였습니다.

심사위원 2 의 지적 사항

서술적 심사평

본 논문은 멀티모달 영상 RAG 파이프라인에서 평가 데이터의 순환성을 차단하고, 검색용 데이터 구성과 검색 계획, 물리 색인에 따른 검색 품질과 비용을 실증적으로 분석한다.

⇒ 연구 범위를 정확히 요약해 주셔서 감사드립니다. 개정 원고에서는 이 분석을 검색 신호와 순위 융합, 배포 및 답변 전과 진단까지 연결하고, 결과의 적용 범위를 데이터·모델·정답 기준과 자원 제약에 따라 명시하였습니다.

연구의 독창성과 실험적 공헌도는 인정되나 몇 가지 수정사항이 필요하다.

⇒ 연구의 독창성과 실험적 공헌을 긍정적으로 평가해 주셔서 감사드립니다. 아래의 각 지적 사항에 따라 수치와 계산 기준을 정정하고, 분석 단위와 재현 정보를 보강하였으며, 최종 PDF 의 제목과 페이지 머리말을 점검하였습니다.

세부 수정 의견

1. 서론에서는 다중 이미지 구성의 의미론적 nDCG@10 이 0.181 에서 0.418 로 증가했다고 기술하였으나, 5.2.2 절과 표 4에서는 0.352 로 제시되어 있어 수치를 일치시켜야 한다.

⇒ 0.418 은 옳기였으므로 0.352 로 정정하였습니다. 다중 이미지 구성의 의미론적 nDCG@10 은 영상 설명문 구성의 0.181 에서 0.352 로 증가하며, 설명문 대비 차이는 +0.171, 군집 95% 신뢰구간은 [+0.018, +0.316]입니다. 서론, 5.2.2 절과 표 4의 수치를 모두 일치시켰습니다.

반영 위치: 1 장 서론, 5.2.2 절, 표 4.

2. 5.2.1 절에서 검색 품질이 최대 4.7 배 부풀려진다고 하였으나, 비순환 기준 0.181 에서 정답 기반 조건 1.000 으로 증가한 경우 약 5.5 배에 해당한다.

⇒ 지적해 주신 계산에 따라 두 통제 주입 경로를 분리하여 정정하였습니다. 정답 조건 주입은 $1.0000/0.1810=5.52$ 로 약 5.5 배이고, 정답 라벨 재진술 주입은 $0.8537/0.1810=4.72$ 로 약 4.7 배입니다.

반영 위치: 5.2.1 절, 그림 2 설명.

3. 4.7 배의 계산 기준을 명확히 제시할 필요가 있다.

⇒ 4.7 배는 검색 문서에 정답 라벨의 의미를 재진술하여 주입한 조건의 배율임을 명시하고, 정답 영상만 남기는 정답 조건 주입의 5.5 배와 구분하였습니다. 두 실험에서는 질의, 코퍼스, 검색 정답 집합과 임베딩 모델을 동일하게 유지하고 주입 대상만 변경하였습니다.

반영 위치: 4.1 절 통제 주입 방법, 5.2.1 절.

4. 5.2.3 절에서는 고결합 질의를 10 개로 분류하였으나 표 5 의 분석 단위는 2 개 쌍으로 제시되어 있다.

⇒ 조건-의미 쌍은 메타데이터 조건 종류와 의미 조건의 조합이며, 고결합 표본은 2 개 조건-의미 쌍에 포함된 10 개 질의로 구성됨을 설명하였습니다. 따라서 2 쌍과 10 질의는 서로 다른 분석 단위를 나타내며 모순되는 수치가 아닙니다.

반영 위치: 5.1.3 절, 5.2.3 절, 표 5.

5. 질의와 쌍의 관계 및 부트스트랩 표본 단위를 설명해야 하며, 외부 데이터셋에서 고결합 조건의 효과가 재현되지 않은 점을 고려하여 해당 결과의 일반화는 제한적으로 서술하는 것이 적절하다.

⇒ 표 5 에서 ‘질의’ 는 질의 단위 부트스트랩 재표집을, ‘쌍’ 은 조건-의미 쌍 군집 단위 부트스트랩 재표집을 의미한다고 명시하였습니다. 고결합 결과는 2 쌍·10 질의에 근거하므로 일반화된 결론이 아닌 탐색적 결과로 한정하였습니다. 외부 데이터셋 비교는 고결합 효과의 재현을 주장하는 근거로 사용하지 않고, 메타데이터 조건을 필수 제약 또는 관심 단서로 해석할 때 나타나는 효과 방향을 비교하는 범위로 구분하였습니다.

반영 위치: 5.1.3 절, 5.2.3 절, 표 5, 5.3 절.

6. 5.2.6 절의 답변 효과 실험은 정확도 수치만 제시되어 있다.

⇒ 답변 모델, 검색 문맥 조건, 문항 수, 디코딩, 채점 기준, 반복 횟수와 불확실성 분석을 방법 절에 추가하고, 조건별 정확도·95% 신뢰구간·주요 대응 차이와 p 값을 표 10 으로 정리하였습니다.

반영 위치: 5.1.3 절, 5.2.6 절, 표 10.

7. 사용한 답변 모델과 프롬프트, 조건별 표본 수, 채점 기준, 반복 횟수 및 불확실성 분석을 구체적으로 제시하고 결과를 표로 정리할 필요가 있다.

⇒ 설명문 실험에는 Qwen2.5-7B-Instruct 와 Llama-3-8B-Instruct 를 사용하였습니다. VRU-Accident 의 6 개 문항 범주에서 각 100 개씩 추출한 4 지선다 600 문항에 검색 문맥 없음, 무관 설명문, 벡터 검색 설명문, 검색 전 조건 적용 설명문과 정답 설명문 조건을 적용하였습니다. 프롬프트는 A-D 기호 하나만 출력하도록 지시하였고, 최대 신규 6 토큰의 탐욕적 디코딩을 조건별로 한 번 수행하였습니다. 처음 출력한 A-D 를 정답 기호와 정확 일치로 채점하고, 문항 부트스트랩 10,000 회와 McNemar 정확 검정으로 불확실성과 대응 차이를 평가하였습니다. 결과는 표 10 에 모델별 정확도와 주요 대비로 제시하였습니다.

반영 위치: 5.1.3 절, 5.2.6 절, 표 10.

8. 특히 무관한 설명문을 제공했을 때 정확도가 증거가 없는 경우보다 22%포인트 높게 나타난 원인도 설명되어야 한다.

⇒ 검색 문맥 없음과 무관 설명문 조건의 차이를 선택지별 응답 분포와 문항 범주별로 분석하였습니다. Qwen2.5-7B-Instruct 는 검색 문맥이 없을 때 전체 문항의 42.0%에서 네 선택지 중 같은 위치의 답을 골랐으나, 무관 설명문을 제공하면 이 비율이 23.8%로 낮아졌습니다. 해당 위치가 실제 정답인 문항의 비율은 21.2%였습니다. 장소·도로 유형 문항의 정확도는 두 답변 모델에서 상승한 반면 사고 유형 문항에서는 하락하였습니다. 이에 따라 약 22%포인트의 상승에는 질문·선택지 형식의 응답 편향과 데이터셋에 반복되는 장소·도로 장면 패턴이 개입했을 가능성이 있음을 설명하고, 관련 검색 문맥의 추가 기여는 무관 설명문 대비 벡터 검색 설명문의 약 13%포인트 차이로 구분하였습니다.

반영 위치: 5.2.6 절, 표 10, 5.3 절.

9. 표 2에서는 설명문 생성 모델을 Qwen2.5-VL-7B-Instruct로 제시하였으나 5.2.2 절에서는 이후 실험에 Qwen3.5-9B를 사용했다고 기술하고 있다.

⇒ 두 설명문 코퍼스의 역할을 실험별로 구분하였습니다. 새로 구축하는 영상 설명문의 기본 생성 모델은 Qwen2.5-VL-7B-Instruct이며, RQ1의 통제 주입과 RQ2의 통합 설계에는 Qwen3.5-9B가 생성한 설명문을 사용하였습니다. RQ2의 생성 모델 비교에서는 동일한 프롬프트와 디코딩 조건을 유지하고 두 모델의 설명문만 교체하였습니다.

반영 위치: 5.1.1-5.1.2 절, 표 2, 5.2.2 절.

10. 각 데이터셋과 실험별로 사용된 설명문 생성 모델을 명확히 구분하여 제시해야 한다.

⇒ 각 RQ에서 사용하는 설명문 생성 모델과 임베딩 모델의 역할을 구분하여 서술하였습니다. 설명문 검색에는 BGE-M3를 사용하고, RQ1 통제 주입과 RQ2 통합 설계의 시각·텍스트 표현에는 Qwen3-VL-Embedding-2B를 사용하며, RQ5의 대규모 이미지 색인에는 CLIP ViT-B/32를 사용합니다. 또한 임베딩 모델이 다른 실험군의 절대 nDCG@10은 직접 비교하지 않는다고 명시하였습니다.

반영 위치: 표 1-2, 5.1.1-5.1.2 절.

11. 본문의 페이지 머리말에 논문 제목과 다른 기존 제목이 반복적으로 남아 있으므로 전체적인 편집과 형식을 점검해야 한다.

⇒ 최종 PDF의 접수 양식, 본문 첫 페이지와 모든 페이지 머리말을 현재 논문 제목인 「종단형 멀티모달 RAG 파이프라인 성능 향상을 위한 비순환 평가 및 검색 품질-비용에 대한 실증 연구」로 통일하였습니다. 저자명과 경북대학교 소속 각주도 접수 정보와 일치하는지 함께 점검하였습니다.

반영 위치: 최종 PDF 접수 양식, 본문 첫 페이지, 전체 페이지 머리말과 저자 소속 각주.