

KIISE-DBR 2026 `8

논문 투고 규정 (Manuscript Submission Guidelines)

https://dbsociety.kr/dbr_submission_guide/

(최종) 제출용 논문 양식

[DB연구 최종본양식.hwp](#)

본 문서는 2026년 8월호 데이터베이스연구(DBR) 투고를 목표로 한 실험을 정리함.
2025~2026년 국내 데이터베이스 연구 동향 조사 결과를 바탕으로 논문 주제 선정과 실험 설계.

This workspace is dedicated to converting the 2025~2026 Korean database research trend survey results into paper topic formulation and experimental setup, targeting submission to the August 2026 issue of *Database Research (DBR)*.

Page containing miscellaneous content

Study Knowledge

Related Works

Paper

DATASET TABLES

Datasets Information

Title

도시 감시 멀티모달 데이터베이스의 저장·색인·검색 구조와 VLM 질의응답 : 비순환 워크로드
기반 정확도·지연·비용 평가

**Storage, Indexing, and Retrieval Structures for Multimodal Urban-Surveillance VLM-QA : A Non-Circular
Workload Study of Accuracy, Latency, and Cost**

최종 수정 : 종단형 멀티모달 RAG 파이프라인 성능 향상을 위한 비순환 평가 및 검색
품질·비용에 대한 실증 연구

An Empirical Study of Non-circular Evaluation and Retrieval Quality-Cost for
Enhancing the Performance of End-to-End Multimodal RAG Pipeline

▼ Topic

대규모 도시 감시 멀티모달 데이터에서 질의마다 전체 원본 영상을 VLM에 직접 입력하지 않고도, 데이터베이스 evidence layer가 자연어 의미 조건과 센서·시공간 메타데이터 조건을 이용하여 소수의 신뢰할 수 있는 근거를 선별하도록 만들고, 이를 위해 필요한 저장 표현·검색 계획·벡터 색인·배포 구조의 선택 기준을 정확도·지연·저장공간·구축비용 관점에서 도출하는 것이다. 이때 구조 비교가 동일 주석 라벨의 재사용으로 왜곡되지 않도록 비순환 평가 체계를 먼저 확립하고, DB 검색 성능의 개선이 최종 VLM-QA 답변 정확도로 전달되는 조건과 한계까지 규명한다.

도시 감시 영상 멀티모달 RAG 파이프라인에서 (1) 평가 순환성(evaluation circularity)을 차단하는 '비순환 평가 체계'를 수립하고, (2) 그 공정한 평가 위에서 벡터 데이터베이스 계층의 설계 선택이 만드는 검색 품질-비용 상충 관계를 종단 간(end-to-end)으로 실증하는 것" 입니다.

- When both natural language queries and metadata conditions are provided, which storage, indexing, and retrieval structures support VLM-based question answering more accurately, faster, and at a lower cost?
 - NL 질의 + 메타데이터 조건 병행 시 어떤 저장·색인·검색 구조가 더 정확·빠르고·저렴한가
 - 논문의 설계 축 비교(RQ2 검색용 데이터, RQ3 검색 계획, RQ4 검색 신호, RQ5 물리 색인·배포)
 - 평가 지표(nDCG@10/Recall@10, p50-p95 지연, 저장량, 구축 시간)에 정확히 대응
 - **논문의 답은 "단일 최적 구성은 없다 - 정답 기준·자원 제약에 따른 조건부 파레토 선택"**
 - 본 질문은 유효하되 답의 형태가 조건부라는 점을 인지하라.
- To support VLM question answering in urban surveillance data combining images/videos, video descriptions (VLM-generated captions), and sensor/spatiotemporal metadata, which storage, indexing, and retrieval structures best balance accuracy, latency, and cost?
 - 사건 유형 설명문은 보완 데이터셋(VRU-Accident의 사고 유형 정답, 지능형 관제 CCTV의 한국어 사건 설명문)에서 만 등장하며 순환성 검증(RQ1) 용도로 사용한다. 따라서 'incident reports' 교체.
 - 논문의 세 원천은 **센서·시공간 메타데이터 / VLM 영상 설명문 / 사람 주석**
- Designing Non-Circular Hybrid VLM-DB Retrieval Workloads and Comparing Storage and Indexing Structures for Multimodal Urban Surveillance Data
 - 필터·문서·정답 3가지가 동일 라벨에서 파생되어 성능이 왜곡되는 순환성 워크로드의 함정을 차단한 '비순환(Non-Circular)' 설계와 Tri-Source 채널 분리 방식 적용 실험
- How do clustered real-world predicates affect vector index recall, compared to conventional random-mask filtering?
 - 기존 random-mask 벤치마크는 실세계 메타데이터의 '군집 상관성(Clustering)' 때문에 Filtered-ANN 성능을 대폭 과대평가하고 있음
 - 이를 해결하기 위해서는 전역 공유 색인이 아닌 지역/부분 색인(Partial Index) 정책이 필수적
- To what extent do improvements in database-level evidence retrieval propagate to final VLM-QA accuracy, and what architectural boundaries govern this propagation?
 - DB 검색층의 성능 향상이 최종 VLM 답변 정확도로 자동 전파되지 않음
 - 소형 코퍼스의 '중개자 벽(Mediator Wall)'과 대형 코퍼스 및 VLM 한계의 '지각 벽(Perception Wall)'이라는 2가지 구조적 경계에 의해 통제된다.
 - 중개자 벽 : DB 인덱스의 변경(Cause)이 VLM으로 들어가는 중개 변수(Mediator: 증거 전달률)를 변화시키지 못함. 이로 인해 답변 성능 향상으로 이어지지 않음
 - 지각 벽 : DB 단에서 증거를 아무리 잘 가져다주어도 VLM 모델 자체의 시각 지각 한계 상한선에 막혀 최종 답변 정확도가 더 이상 오르지 않음.

Keyword

- **멀티모달 도시 교통량 및 감시 도메인 데이터셋**
(Multimodal Urban Traffic Volume and Surveillance Domain Dataset)
- **데이터베이스 계층 아키텍처**
(Database Layer Architecture - Storage, Index, Retrieval)
- **Multimodal RAG (Retrieval-Augmented Generation)**
 - 사용자 입력(Query), 검색 대상 데이터베이스(Retrieval), 그리고 생성 모델(Generation)의 입력 및 출력 단계에서 텍스트, 이미지, 비디오, 오디오, 3D, 센서 데이터 등 '두 개 이상의 모달리티(Multi-modalities)'를 자유롭게 결합하여 상호 보완적으로 정보를 증강하는 기술 패러다임.

- **VLM-QA (Vision-Language Model Question Answering)**
 - 비전-언어 모델(VLM)을 응용 계층으로 채택하여, 비디오 입력 스트림과 다차원 메타데이터를 복합적으로 해석하고 사용자의 자연어 질문에 최종 답변을 도출.
- **비순환 워크로드 (Non-Circular Workload)**
 - 데이터를 물리적 센서 채널, 인공지능 지각 채널, 독립된 인간 평가 채널 등 서로 독립적인 기원(Origin)에서 개별적으로 생성하여 결합한 워크로드.
 - 순환 워크로드 방식의 평가 문제점 개선 방법 — 평가 데이터셋을 구성하는 네 가지 핵심 요소인 [질의(Query) / 필터 조건(Filter Predicate) / 검색 문서(Document) / 정답셋(Ground Truth)]이 단일한 어노테이션 소스(동일한 텍스트 주석)로부터 동시에 파생.
- **Tri-Source Evaluation Protocol**
 - Non-Circular Workload 평가를 위해 **물리 센서 데이터(Predicate), VLM이 Frame에서 직접 생성한 캡션(Document), 인간의 수동 검증 라벨(Relevance/Ground-Truth)**의 3대 독립 기원(Origin)을 융합하여 벤치마크 신뢰성을 보장하는 고유의 데이터 제어 프로토콜.
- **Filtered Vector Search / Scalar-Vector Querying**
 - 고차원 밀집 벡터 간의 유사도 검색(ANNS)과 관계형 스칼라 조건 필터링(예: 시간대, 특정 교차로 ID 등)을 복합 단일 쿼리 파이프라인 내에서 효율적으로 결합 및 가속하는 관계형 벡터 검색 기술.
- **Storage Schema & Granularity Design Space (저장 세분성 및 스키마 설계 공간)**
 - 대용량 비디오 데이터를 데이터베이스에 영속화할 때, 클립 단위 캡션(clip-caption), 프레임별 단일 벡터(frame-vector), 다중 토큰 임베딩(multi-vector), 또는 스칼라-벡터 이중 인덱스 중 정확도와 효율성의 균형을 고려하여 최적의 데이터 레이아웃을 결정하는 아키텍처 범위를 지칭.
- **Partial Vector Indexing**
 - 전체 데이터셋이 아닌 특정 상시 필터 조건(예: 특정 구역, 최근 일자 등)을 만족하는 희소한 데이터 서브셋에만 한정하여 벡터 인덱스(HNSW 등)를 동적으로 배포함으로써 메모리 오버헤드를 극적으로 절감하는 DB 물리 최적화 기법입니다.
- **Relational Vector Database / pgvector**
 - 전용(Proprietary) 벡터 DB와 달리, 전통적인 SQL 관계형 대수 연산자와 최신 벡터 근사 검색 연산(HNSW 등)이 동일한 스키마와 트랜잭션 도메인 내에서 단일 가속 파이프라인으로 구동되는 PostgreSQL(pgvector 확장) 환경을 사용한다.

▼ Motivation

- **(사회적 문제 - 왜 이 시스템이 필요한가?)** 교차로 신호 운영, 보행자·이륜차 등 교통약자 보호, 사고와 이상 상황 대응을 위해 도시 곳곳에서 감시 영상이 상시 수집·축적되고 있다. 관제·수사·교통 실무자는 "오전 10시경 오토바이 2대가 나오는 장면"처럼 시간·장소·객체 조건이 결합된 특정 장면을 신속히 찾아야 하지만, **영상의 축적 속도는 사람이 검토할 수 있는 한계를 넘어섰다.** 따라서 **대규모 영상 집합을 자연어로 질의하고 근거 장면과 함께 답을 받는 시스템은 도시 안전 관제의 실질적 요구가 되었다.**
- **(실용적 한계)** 그러나 축적된 전체 영상과 프레임을 사용자 질의마다 VLM에 직접 입력하는 방식은 문맥 길이 상한 초과와 GPU 연산 비용 폭증을 유발하므로 현실적인 운영 방식이 될 수 없다.
- **(운영적 요구)** 답변 생성 이전에, 데이터베이스 계층이 시공간·센서 메타데이터 조건과 벡터 유사도 검색으로 전체 데이터에서 관련성 높은 소수의 증거(클립·프레임·설명문)를 먼저 선별해야 하며, VLM은 이 검색된 증거 집합만으로 답변을 생성한다. 결국 시스템 전체의 검색 품질과 자원 비용은 이 계층의 물리 설계에 좌우된다.
- **(구조적 불확실성)** 문제는 이 계층의 최적 설계가 자명하지 않다는 점이다.
 - 검색용 데이터 구성 : 영상 설명문, 대표 이미지, 이미지·설명문 결합, 다중 이미지, 이중 색인
 - 검색 계획 : 검색 전·후 조건 적용(prefilter, postfilter), 혼합 검색
 - 검색 신호와 순위 융합 : BM25, 벡터, RRF
 - 물리 색인 : Flat, HNSW, IVF 계열

- 배포 방식 : 전역, 조건별 부분 색인

다섯 설계 축은 **검색 품질, 질의 자연, 저장량, 색인 구축 비용** 사이에 서로 다른 절충을 만든다. 기존 연구는 이 축들을 개별 단위로만 발전시켰을 뿐, 데이터 적재부터 최종 답변까지 하나의 파이프라인에서 통합 측정하지 않았다. 따라서 **정답 기준 (필수 제약인지 관심 단서인지), 조건의 선택도와 데이터의 시공간 군집성, 허용 자연과 자원 제약**에 따라 구성을 선택할 수 있는 실증적 기준이 필요하다.

- **(검증의 함정)** 더 근본적인 문제는 이 비교 자체가 기존 평가 환경에서는 성립하지 않는다는 것이다. 기존 영상 벤치마크는 **메타데이터 조건, 검색 문서, 검색 정답 집합이 동일한 사람 주석에서 함께 파생**되어, 검색기가 장면을 이해하지 못해도 정답 정보의 간접 재사용만으로 특정 전략의 우위가 구성상 보장되는 자기참조적 순환 관계를 내재한다. 이렇게 부풀려진 지표로 선택된 설계가 실제 관제 현장에 배치되면, 사고 검색과 증거 확보가 필요한 순간에 기대 성능을 내지 못하는 사회적 비용으로 되돌아온다.
- **(연구 목표)** 이에 본 연구는 센서 메타데이터, VLM 영상 설명문, 사람 주석의 세 생성 경로를 분리한 비순환 작업 부하를 먼저 확립하고, 그 위에서 다섯 설계 축의 **검색 품질-자연-저장-구축 비용** 절충을 통합 측정하며, **데이터베이스 계층의 검색 개선**이 최종 VLM 답변 정확도로 전파되는 조건과 한계까지 검증한다.

제한 사항 명시

24시간 동작하는 CCTV 영상의 모든 이미지 프레임을 VLM으로 캡션화(임베딩)하고 이를 벡터화하는 방식은 현재 연구의 처리량에서 현실적이지 않다. 현장 적용을 위해서는 원본 영상 보존, 전수 metadata 적재, 주기 및 이벤트 기반 이미지 프레임 선택, 비동기 임베딩 큐, 최근 데이터용 delta 검색과 과거 데이터용 ANN 색인을 분리해야 한다. 본 연구는 이러한 체계에서 사용할 저장 단위·필터 계획·색인 선택의 오프라인 근거를 제공하지만, 스트리밍 적재와 자동 hot/cold 색인 운영 자체를 구현·검증한 것은 아니다.

▼ 용어 통일 (정의)

벡터 데이터베이스 계층

- 후보? : 벡터 데이터 처리(관리) 계층, 논문 투고 시에는 '데이터베이스 계층'이라고 함.
- 요약·주제어에 이미 "벡터 데이터베이스" 사용 중이라 원고 내 정합. VDBMS 서버이[2]·filtered vector search[11]·VBASE[4]·ACORN[5] 등 인용 문헌의 시스템 범주와 일치. Milvus·Weaviate·pgvector 실험 대상과 직결됨.
- pgvector는 관계형 확장이라는 점에서 첫 정의에서 포괄 범위를 명시해야 할 필요가 있음
- 본 논문의 3절에 다음과 같이 정의할 수 있음.

본 연구에서 **벡터 데이터베이스 계층**은 영상에서 파생된 설명문 텍스트와 이미지 임베딩 벡터, 센서 메타데이터를 저장·색인하고, 자연어 의미 조건과 메타데이터 조건을 입력받아 조건 필터링과 벡터·어휘 검색, 순위 융합을 거쳐 상위 증거 클립을 반환하는 계층을 가리킨다. 이는 **전용 벡터 엔진(Milvus, Weaviate, Faiss)과 벡터 확장을 갖춘 관계형 시스템(PostgreSQL/pgvector)을 모두 포괄**한다.

본문에서는 '데이터베이스 증거 계층', '데이터베이스 계층' 등으로 작성되어 있으므로 이를 수정해야 함.

메타데이터 조건

- 논문 내부 용어 주의 : 구조화 조건

비디오 영상(비정형 데이터)과 결합하여 함께 저장되어 있는 센서 및 환경 속성값.

즉 "장소(카메라 ID), 촬영 시각(시간대), 날씨, 교통 신호등 상태 등 구조화된 형태(Table 구조)의 **메타데이터에 대한 필터링 조건식**"을 의미

본문에서는 이 용어를 구조적 조건 또는 메타데이터 조건 (Metadata Predicate / Filter)과 혼용하여 사용됨을 확인함

‘증거’의 명확하지 않은 세 가지 대상 분리

1) DB가 반환하는 것 : 상위 K 검색 결과 (집합)

- 검색 계획이 반환한 클립·프레임·설명문의 순위 목록

2) VLM에 제공되는 형태 : 검색 문맥

- 검색 결과를 VLM 입력으로 구성한 것 (기존 '입력 문맥'=문맥 창 형태 크기와 구분 유지)
- 상위 k 검색 결과로 구성되는 클립·프레임·설명문의 집합

3) 정답 판정 대상 : 관련 클립 / 검색 정답 집합 (relevant clip / qrels)

- 이중 정답 기준을 충족하는 클립 — 이미 논문에 있는 용어

클립 (Clip)

- MSR-VTT (CVPR 2016) — 영상-언어 분야의 정초 벤치마크. 논문 원문이 "10K web video clips", "200K clip-sentence pairs"로 클립을 주석·검색의 기본 단위로 정의합니다. 영상 검색 분야에서 클립 단위 평가의 사실상 표준 기점이다.
- CLIP4Clip (Neurocomputing 2022). 논문 제목 자체가 "An Empirical Study of CLIP for End to End Video Clip Retrieval and Captioning"입니다. 즉 '비디오 클립 검색(video clip retrieval)'은 개별 논문의 조어가 아니라 과제(task) 이름으로 정착된 용어입니다.
- MEVA (WACV 2021) — 본 논문이 이미 인용 중인 참고문헌 [20], 그것도 감시 영상 도메인. MEVA는 데이터를 "4,304 video clips, each 5 minutes long"으로 배포하고 주석도 "266 five-minute-long video clips" 단위로 제공합니다. 감시(surveillance) 도메인에서 클립이 배포·주석 단위라는 것을, 새 인용 추가 없이 기존 참고문헌만으로 증명할 수 있습니다. 이것이 심사 대응에서 가장 강력한 카드입니다.
- 첫째, 본 연구에서 클립(clip)은 데이터셋이 배포하는 mp4 영상 파일 하나에 해당하는 짧은 연속 영상 구간으로, 저장·검색·정답 판정의 기본 단위다. 이는 MEVA[20] 등 감시 영상 데이터셋이 영상을 배포·주석하는 표준 단위 개념과 동일하다.
- 둘째, CLIP 모델과의 표기 구분. 본 논문에는 임베딩 모델 CLIP ViT-B/32(표 2, [3])와 단위로서의 클립이 공존합니다. 국문에서는 '클립'/'CLIP'으로 구별되지만, 정의 문장에 "대문자 CLIP은 시각-언어 임베딩 모델[3]을 가리킨다"를 덧붙이면 발표·구두심사에서의 혼동까지 차단됩니다.
- 셋째, 논문 내 단위 명칭 일관성 점검. 표 1에서 UCA/UCF-Crime는 "세그먼트 6,432개"로 표기되어 클립과 세그먼트가 혼용됩니다. 원 데이터셋의 명명을 따른 것이므로 틀린 건 아니지만, 표 1 각주나 본문에 "원 데이터셋의 배포 단위 명칭을 따른다" 한 줄을 두면 일관성 질문이 봉쇄됩니다.

세 원천 분리 프로토콜

- 프로토콜 : 데이터를 만드는 규칙·절차
- 데이터셋 : 그 규칙을 따라 만들어진 산출물

1. 원천 분리 규칙 : 메타데이터 조건은 센서 기록에서, 검색 문서는 영상 픽셀만 입력받은 VLM 설명문에서, 검색 정답은 사람 주석에서 생성한다.
2. 재사용 금지 규칙 : 정답 라벨·필드가 조건이나 문서로 흘러 들어가는 것을 금지한다.
3. 검증 규칙 : 준수 여부를 자동 검사로 확인한다.

프로토콜이라고 언급해야 하는 이유

결정적 증거는 논문이 이 절차를 서로 다른 세 데이터셋에 적용했기 때문이다. AI Hub 교차로 워크로드는 이 규칙을 준수해 새로 구축한 산출물이고, VRU-Accident와 지능형 관제 CCTV는 같은 규칙을 적용해 수리한 사례입니다(표 3의 수정 전 → 후). 만약 "세 원천 분리"가 그냥 하나의 데이터셋이라면 "그것을 VRU-Accident에 적용한다"는 문장 자체가 성립하지 않습니다. 절차이기 때문에 다른 데이터셋에 이식·적용될 수 있는 것입니다.

세 원천 분리 프로토콜은 특정 데이터셋이 아니라 평가 데이터를 만드는 규칙의 집합이다. ① 조건·문서·정답을 각각 센서 기록·픽셀 전용 VLM 설명문·사람 주석이라는 서로 다른 원천에서 생성하고(원천 분리), ② 정답 라벨의 재사용을 금지하며(재사용 금지), ③ 준수 여부를 자동 검사로 확인한다(검증). AI Hub 교차로 워크로드는 이 프로토콜을 준수해 구축한 산출물이고, VRU-Accident·지능형 관제 CCTV 수리는 동일 프로토콜의 이식 적용 사례다.

▼ Research Question

본 연구는 실제 도시 감시 데이터에서 시각-언어 모델(Vision-Language Model, VLM)의 질의응답에 제공할 **검색 문맥 (Retrieved Context)**을 **벡터 데이터베이스 계층**이 선별하는 문제를 다룬다. 이때 핵심은 단일 최고 성능 구성을 찾는 것이 아니라, 공정한 평가 위에서 자원 제약과 사용 목적에 맞는 구성을 선택할 수 있는 **실증 기준을 세우는 것**이다. 구체적으로 다음의 핵심 질문에 답한다.

평가 순환성이 차단된 실제 도시 감시 워크로드 위에서, 벡터 데이터베이스 계층의 **다섯 설계 축 — 검색용 데이터 구성, 검색 계획, 검색 신호와 순위 융합, 물리 색인, 배포** — 은 검색 품질, 질의 지연, 저장량, 색인 구축 시간 사이에 어떤 절충을 만들며, 주어진 정답 기준과 자원 제약 아래 어떤 구성을 선택해야 하는가? 그리고 그렇게 얻은 검색 개선은 어떤 조건에서 최종 VLM 답변 품질로 전파되는가?

여기서 평가 순환성이란 **질의, 메타데이터 조건(필터), 검색 문서, 검색 정답 집합이 동일한 사람 주석에서 함께 파생되는 상태**를 말한다. 이 상태에서는 특정 검색 방식이 장면 이해와 무관하게 이기도록 처음부터 정해져 있다. 필터 조건과 정답이 같은 주석에서 나오면 필터를 통과시키는 것만으로 정답 클립만 남고(검색 전 조건 적용 nDCG@10 0.97~1.00), 검색 문서에 정답 라벨 문장이 재사용되면 어휘가 겹치는 BM25가 영상을 보지 않고도 상위를 차지한다. 이때 점수는 검색기가 장면을 얼마나 잘 찾는지 가 아니라, 데이터를 만들 때 질의·필터·문서·정답 사이에 겹침을 얼마나 심어 놓았는지를 재는 숫자가 된다. 이런 숫자를 근거로 "필터만으로 충분하다", "어휘 신호를 융합하라" 같은 구성을 선택하면, 주석이 없는 실제 운영 환경에서는 그 우위가 재현되지 않아 잘못된 시스템 설계로 이어진다.

이 핵심 질문을 검증 → 설계 → 전파의 세 단계, 여섯 개 연구 질문으로 분해한다. 다섯 설계 축 가운데 물리 색인과 배포는 "실측 조건에서 어떤 색인 구조를 어느 범위에 두는가"라는 하나의 물리 설계 결정을 RQ5에서 함께 다룬다.

RQ1 평가 타당성 → RQ2 검색용 데이터 → RQ3 검색 계획 → RQ4 검색 신호·순위 융합 → RQ5 물리 색인·배포 → RQ6 답변 전파

검증(RQ1). 센서 메타데이터, VLM 영상 설명문, 사람 주석의 세 생성 경로를 분리한 비순환 작업 부하가 순환성 왜곡을 실제로 진단·차단하는지 검증한다. RQ1이 성립해야 이후 모든 비교가 해석 가능하므로, RQ1은 본 연구 전체의 전제를 보증한다.

설계(RQ2-RQ5). 검증된 워크로드 위에서 벡터 데이터베이스 계층의 다섯 설계 축을 데이터 생애주기 순서로 비교한다. **무엇을 저장하고(RQ2 검색용 데이터), 조건을 언제 결합하며(RQ3 검색 계획), 어떤 신호로 순위를 매기고(RQ4 검색 신호·순위 융합), 어떤 색인 구조를 어느 범위에 배포하는가(RQ5 물리 색인·배포)**. 설계 축 비교는 필수 제약을 반영하는 **엄격한 정답**과 관심 단서를 반영하는 **의미론적 정답**의 두 기준으로 병행 채점하여 질의 의도에 따라 선택 기준이 달라지는지를 드러낸다. 근사 색인의 손실 진단(RQ5)은 Flat 전수 검색 대비 상대 재현율(Recall@10)로 분리 측정하여 색인·필터링 손실이 의미 채점과 섞이지 않게 한다.

전파(RQ6). 마지막으로 벡터 데이터베이스 계층에서 확인된 검색 품질 차이가 관련 클립 회수, VLM의 검색 문맥 인식, 과제 편향의 세 관문을 거쳐 실제 사용자에게 제시되는 답변 정확도로 전파되는 조건과 한계를 규명한다.

- 관련 클립 회수 : 정답이 담긴 클립이 검색 결과에 실제로 들어왔는가?
- VLM의 검색 문맥 인식 : 들어온 클립에서 VLM이 답을 읽어낼 수 있는가?
- 과제 편향 : 그 향상이 정말 검색 덕분인가?

▼ RQ1. 비순환 평가 타당성

[문제 제기 및 개념 정립 → 검색 파이프라인 절차 → 3단계 검증 설계 → 수리 전후 진단 결과 → 통제 주입 정량화 결과 → 결론 및 연결]

같은 주석의 재사용은 검색 점수를 얼마나 왜곡하며, 본 연구의 세 원천 분리 프로토콜은 이를 진단하고 차단할 수 있는가?

RQ1. 비순환 평가 워크로드의 타당성


평가 순환성이 검색 구조의 상대 성능을 왜곡하는가?

핵심 질문: 검색 구조의 효과를 평가하는가, 아니면 데이터 생성 과정의 누수 효과를 평가하는가?

1 연구질문

필터 predicate, 질의 템플릿, 검색 문서, relevance label이 동일한 주석 계보에서 파생되면 평가 순환성이 발생할 수 있다. 이때 prefilter나 BM25의 우위가 실제 검색 능력이 아니라 구조적 보장 때문에 나타날 수 있다. RQ1은 tri-source 워크로드와 이중 정답 평가가 이러한 왜곡을 제거하는지 검증한다.


2 평가 순환성은 어떻게 생기는가?



- 1 정답 속성이 필터에도 사용됨**
정답이 필터 밖으로 제거될 수 없어 prefilter 우위가 구조적으로 보장될 수 있음
- 2 검색 문서가 정답 라벨을 재진술**
문서가 정답을 직접 말해 sparse/BM25가 부당한 이점을 얻을 수 있음
- 3 질의가 정답 속성값 조합으로 생성됨**
질의와 정답 사이의 표면 중복이 커져 실제 의미 검색 능력을 왜곡함

결과: 실제 검색 능력과 무관하게 특정 검색 구조의 성능이 과대평가될 수 있음

3 본 연구의 해결책: 비순환 tri-source 워크로드



✓ 생성 소스를 분리하여 predicate·document·relevance 사이의 직접 누수 경로를 차단

4 RQ1에서 검증하는 것

- ✓ 순환 워크로드에서 특정 검색 방식의 우위가 구조적으로 보장되는가?
- ✓ 정답 라벨 재진술을 제거하면 sparse 검색 성능이 정상화되는가?
- ✓ 비순환 semantic 평가에서 prefilter가 vector-only보다 낮은 성능을 보일 수 있는가?
- ✓ strict와 semantic 정답을 분리했을 때 필터 효과가 다르게 나타나는가?
- ✓ 자동 감사 절차로 predicate·document·relevance 사이 직접 누수 경로가 차단되었는가?

순환 vs 비순환

순환 워크로드

- 구조적 우위 보장
- 성능 과대평가
- 공정성 저하

비순환 tri-source

- 우위 보장 제거
- 타당한 비교
- 검색 구조 효과 검증

5 왜 중요한가?



RQ1은 단순한 데이터 정제 단계가 아니다.

RQ2-RQ6의 비교 결과가 검색 구조 자체의 효과인지, 아니면 데이터 생성 과정의 누수 결과인지를 구분하는 핵심 검증 단계이다.

필터 predicate, 질의 템플릿, 검색 문서 및 relevance label이 동일한 주석 계보에서 파생되는 평가 순환성은 검색 구조의 상대 성능을 어떻게 왜곡하는가? 또한 predicate·document·relevance의 생성 소스를 분리한 비순환 tri-source 워크로드와 이중 정답 평가는 이러한 구조적 우위 보장을 제거하고 타당한 비교를 가능하게 하는가?

평가 순환성 문제는 다음과 같은 경로를 통해 발생할 수 있다.

1. 정답을 정의하는 속성이 필터에도 사용되어 정답이 필터 밖으로 제거될 수 없게 되는 경우
2. 검색 문서가 정답 라벨을 직접 재진술하여 키워드 검색이 부당한 이점을 얻는 경우
3. 질의가 정답 라벨의 속성값을 조합한 템플릿으로 생성되는 경우

이러한 구조에서는 **prefilter**나 **BM25**가 실제 검색 능력과 무관하게 높은 성능을 얻을 수 있다.

이를 방지하기 위해 본 연구는 다음 세 가지 생성 소스를 분리한 **tri-source 워크로드**를 사용한다.

구성 요소	생성 소스
메타데이터 predicate	센서 데이터 또는 독립적인 구조화 메타데이터
검색 문서	영상 픽셀을 기반으로 VLM 등이 생성한 캡션(text) 또는 시각 임베딩
relevance label	별도의 인간 주석 또는 독립적인 정답 판정

RQ1에서는 다음 사항을 검증한다.

- **순환 워크로드**에서 특정 검색 방식의 우위가 구조적으로 보장되는지
- 정답 라벨 재진술을 제거했을 때 sparse 검색 성능이 정상화되는지
- **비순환 워크로드**의 semantic 평가에서 prefilter가 vector-only보다 낮은 성능을 보일 수 있는지
- strict와 semantic 정답을 분리했을 때 필터의 효과가 서로 다르게 나타나는지
- 자동 감사 절차를 통해 predicate-document-relevance 사이의 직접적인 유출 경로가 차단되었는지

RQ1은 이후 RQ2부터 RQ6까지의 비교 결과가 검색 구조 자체의 효과인지, 아니면 데이터 생성 과정에서 발생한 정보 유출의 결과인지를 구분하기 위한 핵심 검증 단계이다.

1단계 : 데이터 적재 및 색인 작업

- **비디오 정보 준비**: 3,000개 영상 클립의 시각 정보(프레임)와 VLM이 작성한 텍스트 설명문(캡션)을 딥러닝 임베딩 모델(BGE-M3 등)에 넣어 고차원 벡터로 변환한 뒤 벡터 DB(Faiss 등)에 저장합니다.
- **메타데이터 저장**: 각 영상의 조건(시간대, 신호등 상태, 교통량 등)은 메타데이터 테이블에 따로 저장해 둡니다.

2단계 : 사용자 질의 및 필터 조건 입력

- 평가용 질의 85개를 하나씩 DB에 입력합니다.
- 이때 질의는 두 가지 정보를 동시에 가지고 있습니다.
 1. 자연어 검색어 텍스트: 예) "주차된 차량이 있는 빗길 도로 장면"
 2. 메타데이터 필터 조건: 예) 시간대 = 오전, 황색 신호 = 있음

3단계 : 전략별 (코드 B0~B5) 벡터 데이터베이스 검색 연산 수행

설계는 **진단** → **정량화** → **차단**의 세 부분으로 구성된다. 공통 기반은 **새 원천 분리 프로토콜**이다: 메타데이터 조건은 센서 기록에서, 검색 문서는 영상 픽셀만 입력받은 VLM의 설명문에서, 검색 정답 집합은 사람 주석에서 각각 독립적으로 생성하여, 정답을 가려내는 데 쓰인 라벨이 조건이나 문서로 재사용되는 경로를 원천 차단한다.

진단

기존 워크로드 수리 전후 비교. 정답 정보가 검색 문서·메타데이터 조건에 직접 노출되어 있던 기존 작업 부하 2종(VRU-Accident, 지능형 관제 CCTV)에 분리 프로토콜을 적용하고, 동일 질의에서 수리 전후의 검색 점수를 비교한다.

정량화

(통제 주입 실험). 자체 구축한 비순환 워크로드(AI Hub 교차로)에 순환성 요인을 의도적으로 다시 주입하여 점수가 얼마나 부풀려지는지 측정한다.

순환성이 유입되는 두 경로를 각각 검사한다.

- ① **정답 기반 조건 주입**: 정답 정보를 메타데이터 조건에 반영해 정답 영상만 후보로 남김(조건 경로 유출)
- ② **정답 라벨 재진술 문서 주입**: 정답의 의미를 문장으로 풀어 검색 문서에 추가(문서 경로 유출). 점수 상승이 단순 후보 수 감소 때문이라는 반론을 배제하기 위해, 각 질의의 정답 영상 수와 동일한 수를 무작위 선택하는 대조 조건을 1,000회 반복해 비교한다.

차단

(자동 검사). 메타데이터 조건과 정답 집합의 출처 분리 여부, 메타데이터에 정답 필드 미포함, 검색 문서에 정답 라벨·내부 필드명 미노출을 자동으로 확인하는 순환성 검사를 워크로드 구축 절차에 내장한다.

4단계 : 상위 10개 영상 ID 리스트 반환 (Top-10 Retrieval)

벡터 데이터베이스는 각 전략별 계산이 끝나면 최종적으로 가장 관련성이 높다고 판단한 상위 10개 영상 클립의 ID 리스트를 도출합니다.

- (예: [Clip_102, Clip_045, Clip_891, ...])

5단계 : 정답표(Ground Truth) 대조 및 자동 채점 (nDCG@10 계산)

사람이 사전에 일일이 작성해 둔 실제 정답 영상 ID 표(Ground Truth)와 DB가 뽑아온 Top-10 영상 ID 리스트를 대조한다.

- 채점 방식 :
 - "DB가 뽑아온 Top-10 안에 진짜 정답 영상이 몇 개나 들어있는가?" (Recall@10)
 - "진짜 정답 영상이 1등, 2등처럼 얼마나 상위 순위에 예쁘게 잘 배치되었는가?" (nDCG@10)
 - 이 수식을 계산해 점수(0.0 ~ 1.0)를 자동으로 산출합니다.

데이터셋 및 검색 전략별 순환성 수정 전/후의 벡터 검색 결과 성능 비교

검색 코드	데이터셋 · 검색 방식	수정 전(순환)	수정 후 (엄격한 정답)	수정 후 (의미론적 정답)
B0	VRU-Accident / 메타데이터 단독	0.2102	0.1449	0.1449
B1	VRU-Accident / BM25 어휘 검색	0.4495	0.0918	0.1607
B2	VRU-Accident / 벡터 단독 검색	0.4476	0.1845	0.2649
B3	VRU-Accident / 검색 전 조건 적용	0.9488	0.3020	0.2974
B4	VRU-Accident / 검색 후 조건 적용	0.9736	0.3174	0.2974
B5	VRU-Accident / 혼합 검색	0.9651	0.2771	0.2600
B0	지능형 관제 CCTV / 메타데이터 단독	0.6985	0.2778	0.2778
B1	지능형 관제 CCTV / BM25 어휘 검색	0.9600	0.1111	0.1667
B2	지능형 관제 CCTV / 벡터 단독 검색	0.7014	0.6285	0.6285
B3	지능형 관제 CCTV / 검색 전 조건 적용	1.0000	0.8395	0.8395
B4	지능형 관제 CCTV / 검색 후 조건 적용	1.0000	0.8395	0.8395
B5	지능형 관제 CCTV / 혼합 검색	0.9977	0.5537	0.5537

통제 주입 실험의 3단계 절차

이 실험은 데이터 3,000개, 질의 85개, AI 모델을 통제한 상태에서 4가지 실험 방식만 바꾼다.

- 비순환 기준선 (Baseline)
- 정답 기반 조건 주입
- 라벨 재진술 문서 주입
- 무작위 대조군

1단계 : 통제 환경 설정

1. 영상 데이터: AI Hub 교차로 영상 3,000개 클립
2. AI 임베딩 모델: Qwen3-VL-Embedding-2B (2,048차원 벡터 변환기)
3. 질의(Query) 세트: 85개 테스트 질문
4. 사람의 정답표: 사람이 따로 채점해 둔 진짜 정답 리스트

2단계 : 4가지 실험 방식의 세부 절차

① 비순환 기준선 (Baseline) - 0.1810

1. AI(Qwen3.5-9B)에게 영상 픽셀 화면만 보여주고 캡션을 쓰게 합니다 (정답 힌트 단어 0건 확인).
2. 작성된 캡션을 임베딩 모델로 바꿔 벡터 DB에 넣습니다.
3. 조작 없는 정상 센서 필터 + 정상 캡션 벡터 DB로 검색을 돌립니다.

메타데이터, VLM 기반 영상 설명문, 사람 주석을 세 원천 분리 상태로 구축하여 벡터 검색을 수행한다.

- 정직하게 치른 시험과 같으며 정답 유출이 완전히 차단된 상태에서 시스템이 실제로 달성하는 점수
- 낮아 보이지만 이것이 이 과제의 진짜 난이도이며, 이후 모든 설계 비교(RQ2~RQ5)의 출발점이다.

② 정답 기반 조건 주입 (Oracle Filter) - 1.0000

1. 캡션 벡터 DB와 질의는 '비순환 기준선'의 경우와 동일하게 구축한다.
2. 각 질의에 대해 센서 메타데이터 조건 대신 그 **질의의 검색 정답 집합(qrels) 자체를 필터 술어로** 사용한다. "조건을 통과한 클립 = 정답 클립"이 되도록 후보 집합을 정의한 것이며, 메타데이터 조건이 정답과 동일 주석에서 파생되는 순환 상황을 재현한다.
3. 치환된 후보 집합 안에서 기준선과 동일한 벡터 유사도로 상위 k를 산출한다.
4. 동일 후보 수의 무작위 필터를 1,000회 반복(0.120)하여, 점수 상승이 후보 축소 효과가 아니라 정답 정보 때문임을 분리한다.

메타데이터 필터링 규칙에 정답 정보를 주입한다. 그 외의 조건은 모두 동일하게 실험한다. 이는 실제 정답인 영상들만 통과될 수 있도록 메타데이터 조건을 유출하는 것이다.

- 순환성의 조건(필터) 경로 유출을 재현한 것이다. 메타데이터 필터가 정답 영상을 미리 알고 그것만 후보로 남기면, 검색기가 장면을 전혀 이해하지 못하더라도 좋은 점수가 나온다.

③ 라벨 재진술 문서 주입 (Full Label Restatement) - 0.8537

1. 메타데이터 필터, 질의 85개, 채점 기준(qrels)은 비순환 기준선과 완전히 동일하게 유지한다. 이 조건에서 달라지는 것은 검색 문서의 텍스트 내용뿐이다. ②(오라클 필터)가 조건 경로를 조작했다면, ③은 문서 경로만을 조작한 실험 환경이다.
2. **재진술 문장 부착**. 3,000개 영상 캡션 중 사람 주석이 정답으로 판정한 클립의 캡션 끝에, 해당 의미 조건의 정답 판정 정의 문장을 그대로 이어 붙인다. 이 문장은 모델이 생성하는 것이 아니라 조건별 고정 문장 5종이며(예: 주차 차량 조건 → "This clip shows a vehicle parked at the roadside."), 질의문의 관련성 결과 사실상 동일한 문구다. 한 클립이 여러 조건의 정답이면 여러 문장이 붙는다. 부착된 (클립, 문장) 연결의 총수는 1,367건이다.
3. **오염 문서의 재색인·재임베딩**. 문장이 부착된 캡션 전체를 다시 토큰화하여 **BM25 역색인을 재구축하고, 동일 임베딩 모델(BGE-M3)로 재임베딩하여 오염된 벡터 컬렉션**을 만든다. 이때 두 가지 통제 장치가 작동한다: (i) 깨끗한 문서·오염 문서·질의를 같은 세션에서 한 번에 재임베딩하여 임베딩 세션 차이가 점수에 섞이는 것을 차단하고, (ii) 부착 문장이 모델 입력 길이 한도에서 잘려 나가지 않음을 자동 검증한다(잘리면 주입이 무효가 되므로)
4. **동일 검색 실행**. 오염된 컬렉션을 대상으로 기준선과 같은 검색을 실행해 nDCG@10을 재측정한다. 결과는 0.181 → 0.8537(+0.673, 4.7배)이다. 보조로 부착 비율을 0% → 25% → 50% → 75% → 100%로 바꾸는 용량 실험을 각 200회 반복하여, 부풀림이 주입량에 비례해 커지는 것까지 확인했다.

VLM이 생성한 **영상 설명문에 '해당 영상이 왜 정답인지 설명하는 라벨 문장'을 추가로 덧붙여 주입**한다. 그 외의 조건은 모두 동일하게 실험한다. 이 경우, 벡터 임베딩 모델이 영상 설명문에 포함된 정답 힌트를 해석하여 유사도를 높게 계산할 수 있다.

왜 ②는 1.000인데 ③은 0.854에서 멈추는가?

- 오라클 필터는 후보 자체가 전부 정답이라 만점이 구조적으로 보장되지만, 재진술 주입에서는 비정답 문서 2,000여 개가 코퍼스에 그대로 남아 순위 경쟁이 존재한다. 힌트 문장이 정답 클립을 강하게 끌어올리지만 완벽하게는 못 올린다. 즉 문서 경로 유출은 강력하지만, 구조적 보장은 아닌 부풀림이며, 이 차이가 두 유출 경로의 성격 차이를 보여 준다.

기존 벤치마크에서 검색 문서(캡션)가 정답 주석과 같은 원천에서 파생되어 라벨 문장을 재진술하는 상황. 즉 "문서가 정답의 근거 문장을 이미 담고 있는" 데이터 구성을 통제된 형태로 재현한 것이다. 실제 사례로, 정직한 VLM 캡션이 "전경에 주차 차량이 없다"고 서술한 정답 클립조차 재진술 문장이 붙는 순간 질의와의 문구 일치만으로 상위로 올라간다.

④ 무작위 대조군 (Random Same-Selectivity Control) - 0.1200

정답 필터를 사용하면 검색 대상이 전체 3,000개 영상에서 소수의 부분집합으로 크게 줄어들므로, 성능 폭등이 정답 유출 때문이 아니라 단순히 찍어서 맞출 확률이 높아진 착시 현상일 수 있다는 의문을 해소할 필요가 있었습니다.

이를 검증하기 위해 연구진은 각 질의마다 정답 필터가 통과시킨 실제 후보 개수와 정확히 동일한 수의 영상 클립을 무작위 대조군의 후보 수로 1:1 매칭하여 설정했습니다.

예를 들어 특정 질의에서 정답 필터가 후보를 69개로 줄였다면 무작위 대조군 역시 정확히 69개의 후보 개수를 할당받도록 통제함으로써 '후보 비율(선택도)'이라는 변수를 완벽히 동일하게 유지했습니다.

그 후 전체 3,000개 영상 클립 중에서 정답 여부와 상관없이 지정된 개수만큼 비복원으로 영상을 무작위 추출한 뒤, 그 부분집합 안에서 동일한 벡터 유사도 검색을 수행하여 점수를 산출했습니다. 특히 단 한두 번의 제비뽑기 운에 따른 오차를 방지하기 위해 85개 질의 전체에 대해 고유한 시드를 부여하고 동일한 무작위 추출 검색을 총 1,000회 반복 실행하여 그 결과를 종합 평균했습니다.

실험 결과 1,000회 무작위 대조군의 평균 점수는 0.1200으로 집계되었으며, 1,000번의 반복 동안 단 한 번도 필터를 아예 적용하지 않은 비순환 기준점 점수인 0.1810을 넘어서지 못했습니다. 이는 정보가 없는 상태에서 단지 후보 개수만 무작작 줄이는 행위는 검색 성능에 아무런 도움이 되지 않으며, 오히려 진짜 정답 영상을 제외시켜 점수를 떨어뜨린다는 것을 보여줍니다.

결국 정답 필터에서 나타난 1.0000으로의 성능 폭등은 후보 수 감소에 따른 착시 효과가 전혀 없으며, 오직 정답 정보를 미리 알고 유출시켰기 때문이라는 인과관계를 완벽하게 입증하는 최종 근거가 됩니다.

‘정답 기반 조건 주입’ 방식에서 점수가 높아진 이유가 단지 ‘후보 수가 줄어들어서’인지 검증하는 대조군 실험. 실제 정답 기반 조건 주입 방식에서 필터를 통과하면 영상 개수가 3,000개에서 5개로 줄어들 수 있다. 이 경우 ‘정답이 유출’되어서 생긴 점수 향상이 아니라 ‘후보 수가 줄어서’ 생긴 점수 향상으로도 의심할 수 있다. 따라서 이를 검증하기 위해 필터가 남긴 후보 수와 정확히 똑같은 개수의 영상(동일 선택도)을 전체 3,000개 중에서 아무 상관없는 영상으로 무작위(Random) 추출하는 실험을 1,000회 반복한다.

통제 실험 : “정답 정보 통제 주입 실험 전체 결과 (nDCG@10)” 내용을 표 형식으로 다시 정리한 것.

실험 조건 (Treatment)	nDCG@10 점수	효과량 (Δ)	점수 부풀림 (배)	질의 95% 신뢰 구간 (Query)	군집 95% 신뢰 구간 (Cluster)	비고 / 통제 방식
① 비순환 기준선 (Clean Baseline)	0.1810	기준 (0)	1.0배	-	-	정답 유출이 완전히 차단된 정상 상태
② 정답 기반 조건 주입 (Oracle Filter, C1)	1.0000	+0.8190	5.5배	[+0.7802, +0.8553]	[+0.7380, +0.8817]	메타데이터 필터에 정답 영상 유출
③ 라벨 재진술 문서 주입 (Label Restatement, C2)	0.8537	+0.6727	4.7배	[+0.6261, +0.7182]	[+0.5675, +0.7520]	검색 텍스트 캡션에 정답 문구 추가 (1,367개 간선)
④ 무작위 대조군 (Random Control, 1,000회)	0.1200	-0.0610	0.66배	[0.0856, 0.1293]	-	②와 동일 선택도 (후보 수)로 1,000회 무작위 추출 (Replicate 범위)

검색기는 그대로 두고 데이터 구성에만 변화를 주었더니, nDCG@10 점수가 0.18에서 1.00까지 치솟았다. 그러나 같은 크기의 무작위 조작으로는 전혀 오르지 않았다. 이는 점수의 비정상적인 부풀림의 원인은 '정답 정보의 재사용'에 있다.

실험 결과 및 통찰

1. 검색 전 조건 적용 및 검색 후 조건 적용의 누출 반응

- 수정 전에는 **정답 메타데이터가 유입**되어 검색 전/후, 혼합 검색 모두 점수가 0.94~1.0000 수준으로 비정상적 폭등했다.
- 수정 후 라벨 유입이 차단되면서 현실적인 점수로 측정(VRU 0.3174, CCTV 0.8395)되었다.

2. BM25 어휘 검색의 명확한 유출 붕괴

- CCTV 데이터셋에서 텍스트 문서에 정답 키워드가 유출되던 수정 전 점수는 0.9600이었으나, 라벨 재진술 문장을 지운 수정 후에는 0.1111로 가장 크게 하락(Collapse)했습니다.

3. 혼합 검색의 순위 오염 현상

- 약한 변별력을 지닌 BM25 어휘 검색이 융합된 혼합 검색은 두 데이터셋 모두에서 단순 검색 전 조건 적용 시 벡터 검색보다 오히려 성능이 낮게 측정(VRU 0.3174 → 0.2771, CCTV 0.8395 → 0.5537)되어, 검증되지 않은 어휘 신호의 무분별한 융합 위험성을 보여준다.

조작 변인: 정답 정보 주입 2종(정답 영상 필터 / 라벨 재진술 문서) + 기존 워크로드 수정 전후

통제: 모델·코퍼스·질의 고정, 동일 선택도 무작위 대조 1,000회

데이터·지표: VRU-Accident·지능형 관제 CCTV·AI Hub, nDCG@10

판정 근거: 0.9736 → 0.3174 하락(표 3), 주입 시 0.181 → 1.000/0.854(그림 2b)

▼ RQ2. 검색용 데이터 구성

- mp4 영상 클립의 시각 정보를 검색 가능한 형태로 변환해 저장하는 형식.
- ① **영상 설명문**: 클립 전체를 요약한 텍스트(**Qwen2.5-VL-7B-Instruct**가 클립 중간 이미지로 2~4문장·최대 110토큰 생성), 클립당 1벡터. 유일하게 **어휘 문서**를 갖춰 **혼합 검색**까지 4개 검색 계획 모두 지원.
- ② **대표 이미지**: 클립 대표 단일 프레임 벡터, 클립당 1건 (설명문 대비 품질 차이 없음, $\Delta+0.005$).
- ③ **이미지·설명문 결합**: 두 정보(VLM이 생성한 영상 설명문 + 대표 이미지)를 단일 벡터로 결합. 저장 용량 증가 없이 적용 가능한 대안 ($\Delta+0.037$, CI에 0 포함).
- ④ **다중 이미지**: 클립당 최대 3개 주요 프레임 벡터. 의미론적 정답 최고(0.352, $\Delta+0.171$ 유의)이나 저장 2.8배 (24.6 → 68.4MB)·p50 지연 3배 이상(1.15 → 3.65ms), 저장 방식 전체 BH 보장 $p=0.112$ 로 보편 효과는 단정 불가.
- ⑤ **설명문·이미지 이중 색인**: 설명문 벡터 색인과 다중 이미지 벡터 색인을 독립 구축해 각각 검색 후 RRF($k=60$)로 융합하는 두 벡터 신호의 결합 — 다섯 구성 중 최고 비용(93.0MB, 4.96ms). 형식 비교 임베딩은 Qwen3-VL-Embedding-2B(2,048차원) 단일 멀티모달 공간.

조작 변인: 검색용 데이터 5구성 (설명문/대표/결합/다중/이중)

통제: 벡터 단독+Flat 전수, Qwen3-VL-Embedding 고정; 생성 VLM 교체 보조 실험

데이터·지표: 85질의, 이중 정답 nDCG@10+p50+저장량

판정 근거: Δ vs 설명문 기준선, 군집 부트스트랩 95% CI, BH 보장(표 4)

▼ RQ3. 검색 계획

- 조건을 언제 어떻게 적용할지 정하는 방식
- ① **벡터 단독 검색** (조건 없음; Δ 의 기준선, 의미론적 기준 최고 0.170)

- ② **검색 전 조건 적용** (조건 통과 부분집합 내 벡터 검색; 엄격한 정답 기준 $\Delta + 0.0983$ 유의 - 논문은 '조건 충족이 정답에 강 제된 자명한 결과'로 해석)
- ③ **검색 후 조건 적용** (벡터 상위 200 후보에서 불부합 제거, 의미론적 0.150으로 검색 전보다 낮음)
- ④ **혼합 검색** : 메타데이터 조건으로 **사전 필터링한 후보군** 내부에서, **BM25 어휘 순위**와 **벡터 유사도 순위**를 각각 독립적으 로 실행한 후, 검색 신호에서 도출된 개별 순위 결과를 **역순위 융합(Reciprocal Rank Fusion, RRF)** 알고리즘으로 파이프 라인을 결합하여 단일 최종 순위를 산출한다.

이를 통해 총 데이터 '검색용 데이터 구성' 방식 5개와 '검색 계획' 방식 4개를 선정했다. 다만, 검색 계획에서의 '혼합 검색'은 텍 스트 문서가 갖추어져 있어야 하므로 '영상 설명문' 데이터 구성에서만 가능하다는 점으로 인해 본 실험에서 '데이터-계획' 조합 은 $(1 \times 4) + (4 \times 3) = 16$ 개이다.

- 영상 설명문 x (벡터 단독, 사전, 사후, 혼합) = 4
- (대표, 이미지-설명 결합, 다중, 이중 색인) x (벡터 단독, 사전, 사후) = 12

조작 변인: 검색 계획 4종(단독/전/후/혼합)

통제: BGE-M3+Flat 전수, 3,000 설명문, 질의당 10회×총 95,200회

데이터-지표: 결합도 증화(Cramér's $V < 0.3 / \geq 0.3$), 질의 표본 3종

판정 근거: Δ vs 벡터 단독(표 5); UCA 129질의 외부 재현(표 6)

RQ 3. (메타데이터 필터와 벡터 검색의 결합 계획)

자연어 의미 조건과 메타데이터 predicate가 함께 주어질 때, predicate를 hard constraint 또는 soft intent로 해석하는 방 식과 predicate-relevance 결합도에 따라 prefilter, postfilter, single-stage 및 vector-only 계획의 상대적 효과는 어떻 게 달라지는가?

RQ3. 메타데이터 필터와 벡터 검색의 결합 계획

어떤 질의 계약과 결합도에서 어떤 필터 계획이 적절한가?


자연어 의미 조건과 메타데이터 predicate가 함께 주어질 때, predicate를 hard constraint 또는 soft intent로 해석하는 방식에 따라 검색 계획의 상대 효과가 달라진다.

1 연구질문

핵심 질문:

“prefilter가 항상 우수하냐?”가 아니라,
“어떤 질의 계약과 predicate-relevance
결합도에서 어떤 계획이 적절한가?”


- predicate는 경우에 따라 hard constraint일 수도 있고 soft intent일 수도 있음
- strict relevance와 semantic relevance를 분리해서 평가해야 함
- 따라서 동일한 계획도 평가 기준에 따라 장단점이 달라짐



2 비교 대상 검색 계획



3 relevance 기준 분리



4 계획별 직관적 비교

방법	1. 메타데이터 활용 방식	2. strict 적합성	3. semantic 적합성	4. 주요 위험 / 한계
A vector-only	메타데이터 활용 없음	낮음	높음	⚠ 조건 위반 가능
B prefilter	선필터 (hard constraint)	높음	중간~낮음	⚠ 관련 증거 제거
C postfilter	후필터	중간	중간	⚠ recall drop
D single-stage	탐색 중 통합	높음	높음	⚠ 구현 복잡
E metadata-only	구조화 조건만 사용	강간~높음	낮음	⚠ 의미 정보 손실

5 핵심 해석 포인트

- 1 RQ3는 ‘최고의 단일 계획’을 찾는 문제가 아니라, 질의 계약과 평가 기준에 맞는 계획을 선택하는 문제이다.
- 2 strict에서는 predicate를 hard constraint로 다루는 계획이 유리할 수 있다.
- 3 semantic에서는 과도한 필터링이 오히려 관련 증거를 잃게 만들 수 있다.

★ 결론: ‘prefilter가 항상 최고’가 아니라, ‘predicate를 어떻게 해석하느냐’가 계획 선택의 핵심이다.

RQ3에서는 메타데이터 조건을 벡터 검색 과정의 어느 단계에서 적용할 것인지를 비교한다.

비교 대상은 다음과 같다 (strict와 semantic relevance를 분리).

질의 계획	처리 방식
vector-only	메타데이터 필터 없이 의미 유사도만으로 검색
prefilter	predicate를 먼저 적용해 후보 집합을 제한한 후 벡터 검색
postfilter	전체 코퍼스에서 벡터 후보를 검색한 후 predicate를 적용
single-stage	벡터 색인 탐색 과정에 predicate 판정을 통합
metadata-only	벡터 유사도 없이 구조화된 메타데이터 조건만 사용

각 방법은 서로 다른 장단점을 가진다.

- **prefilter**는 검색 공간을 줄일 수 있지만 관련 증거를 사전에 제거할 위험이 있다.
- **postfilter**는 의미 검색 범위를 유지하지만, 상위 후보가 필터에서 탈락하면 충분한 결과를 반환하지 못할 수 있다.
- **single-stage**는 필터와 벡터 탐색을 동시에 수행하지만 색인 및 실행 엔진의 복잡도가 증가한다.

- **vector-only**는 의미상 관련된 증거를 폭넓게 찾을 수 있지만 명시적인 사용자 조건을 위반할 수 있다.
- **metadata-only**는 빠르고 해석하기 쉽지만 자연어 의미를 처리하지 못한다.

RQ3에서는 특히 다음 변수의 영향을 분석한다.

- predicate 선택도 : 전체 데이터 중 조건을 통과하는 비율
- predicate-relevance 결합도
- predicate의 정확도와 누락률
- hard constraint와 soft intent의 구분
- 검색 후보 수와 최종 반환 수
- strict relevance와 semantic relevance의 차이

Strict 평가에서는 predicate가 정답 조건의 일부이므로 prefilter가 높은 성능을 보이는 것이 자연스러울 수 있다. 그러나 **semantic** 평가에서는 관련 증거가 predicate를 만족하지 않을 수도 있으므로 prefilter가 재현율을 낮출 가능성이 있다.

따라서 RQ3은 **질의 계약과 데이터 특성에 따른 적절한 필터 적용 시점**을 규명한다

▼ RQ4. 검색 신호와 순위 융합

1. 검색 신호와 순위 융합 (RQ4) — 순위의 근거와 순위 통합 방식, 4개: ① 메타데이터 단독(필터 통과 클립을 식별자 순 반환 — 조건-의미 결합도를 재는 기준선, 0.218/0.217), ② BM25 어휘(설명문 어휘 일치; 비순환 평가에서 0.017/0.050으로 취약), ③ 벡터(임베딩 유사도, 0.059/0.170), ④ BM25-벡터 RRF(두 순위의 역순위 합산; $0.133 < \text{벡터 단독 } 0.154$ 로 개선 없음). ※ 텍스트-이미지 간 RRF는 이 축이 아니라 축 1의 이중 색인 소속.

RQ: RQ4

조작 변인: 검색 신호 4종(메타 단독/BM25/벡터/RRF)

통제: 동일 후보군·전 조건 적용 상태 고정

데이터·지표: 이중 정답 nDCG@10; 지식그래프 재조합 보조(Lift 0.002)

판정 근거: 전 항목 이득 없음 → 순환성 제거 후 어휘 신호 취약 입증

RQ 4. (검색 신호 및 순위 융합 방식)

메타데이터, **sparse** lexical matching, **dense** semantic retrieval 및 시각 검색이 제공하는 서로 다른 신호를 단독 또는 융합하여 사용할 때, 어떤 검색 및 순위 융합 방식이 질의 유형과 증거 표현에 따라 가장 높은 검색 품질을 제공하는가?

RQ4. 검색 신호와 순위 융합 방식

어떤 검색 신호를 어떻게 결합할 때 질의 유형별 검색 품질이 가장 높아지는가?

RQ3이 predicate의 적용 위치를 다룬다면, RQ4는 metadata-sparse-dense-visual 신호를 단독 또는 융합하여 어떻게 결합할지를 다룬다.

1 연구질문

핵심 질문:


“하나의 융합 방식이 항상 최고인가?”가 아니라, “어떤 질의 유형에서 어떤 검색 신호가 서로 보완적인가?”

- 단일 신호와 융합 신호를 모두 비교
- 질의 유형별로 최적 조합이 달라질 수 있음
- 품질 향상이 추가 지연·운영 복잡성을 정당화하는지도 평가




2 비교 대상 검색 방식


주의: 여기서 hybrid는 메타데이터 필터 + 벡터 검색 결합이 아니라, 서로 다른 검색 신호(BM25-dense-visual)를 결합하는 의미이다.



3 질의 유형별 필요한 검색 신호



4 평가 시 주의점: 비순환 워크로드 필요



5 핵심 해석 포인트

검색 방식	강한 질의 유형	기대 품질	주요 비용/한계
metadata-only	명시적 조건 질의		의미 정보 부족
sparse	어휘 중심		녹후에 취약
dense text	의미 중심		표현 다양성 대응, 그러나 lexical 강화를 제공할 수 있음
visual	시각 중심		시각 인덱스 비용 큼
sparse-dense hybrid	어휘+의미 혼합		점수 결합 설계 필요
text-visual fusion / dual-index	복합 질의		지연·운영 복잡성 증가
RRF	다양한 신호 결합		특히 리미트 rank 기반, 세부 점수 높게

결론: ‘하나의 최고 융합 방식’보다 ‘질의 유형별 보완 신호 조합’이 더 중요하다.

1 어휘 중심 질의에서는 sparse가 강할 수 있다. 2 의미 중심 질의에서는 dense가 유리할 수 있다. 3 시각 또는 복합 질의에서는 visual/text-visual fusion의 가치가 커진다. 4 융합의 품질 향상은 지연과 운영 복잡성을 함께 고려해 판단해야 한다.

RQ3이 predicate의 적용 위치를 다룬다면, RQ4는 서로 다른 검색 신호를 어떻게 결합할지를 다룬다.

검색 방식	주요 검색 신호	특징
metadata-only	구조화된 장소·시간·센서·신호 조건	DB 필터링 방식. 정확하지만 유연성 없음.
BM25 또는 sparse retrieval	질의와 문서 사이의 단어 및 어휘 일치	정확한 단어 매칭. 오타나 동의어에 취약.
dense text retrieval	질의와 캡션 사이의 의미적 유사도	의미와 맥락 이해. 키워드 정확도가 아쉬울 수 있음.
visual vector retrieval	질의 표현과 영상 프레임 또는 클립의 시각적 유사도	텍스트 없이 시각적 유사성(장면)만으로 검색.
sparse-dense hybrid	어휘 일치와 의미 유사도 결합	단어 매칭과 문맥 이해의 장점을 결합한 정석 구조.
text-visual fusion	텍스트 검색과 시각 검색 결과 결합	글자 정보와 화면 이미지 정보를 한 데 엮는 멀티모달 융합.
RRF	개별 검색기의 순위 위치를 이용한 Reciprocal Rank Fusion	두 종류의 검색 엔진을 따로 돌린 뒤 나중에 합치는 아키텍처.

dual-index fusion	캡션 색인과 시각 색인을 독립 검색한 후 점수 또는 순위를 통합 (여러 검색 결과의 '순위')	점수 체계가 다른 검색기들의 결과를 공정하게 합치는 알고리즘.
-------------------	--	------------------------------------

본 연구에서는 hybrid를 BM25, dense retrieval, visual retrieval 등 서로 다른 검색 신호를 결합하는 방식으로 정의한다.

RQ4에서는 질의 유형을 구분하여 분석한다.

- 구체적인 객체명이나 장소명이 포함된 어휘 중심 질의
- 표현은 다르지만 의미가 유사한 의미 중심 질의
- 색상, 자세, 공간 관계 등 시각적 정보가 중요한 질의
- 텍스트와 시각 정보가 동시에 필요한 복합 질의
- 메타데이터 조건과 자연어 의미가 함께 제시된 혼합 질의

또한 라벨 재진술이 포함된 순환 데이터에서는 BM25의 효과가 과대평가될 수 있으므로, sparse 검색의 평가는 반드시 정답 라벨 유출이 제거된 워크로드에서 수행한다.

RQ4의 목적은 어떤 검색 신호가 어떤 질의 유형에서 실제로 보완적인 정보를 제공하는지를 확인하고, 융합으로 인한 품질 향상이 추가 지연과 운영 복잡성을 정당화하는지를 평가하는 것이다.

▼ RQ5. 물리 색인 및 배포

1. 물리 색인 (RQ5) — 벡터를 저장·탐색하는 자료구조, 4종: ① Flat(전수 비교 정확 검색, 재현율 기준선 1.0; p50 13~14ms, 구축 0.1초대), ② HNSW(그래프 근사 색인; M=32, efConstruction=200, efSearch∈{64,256}; 재현율 0.997+, p50 0.04ms대, 구축 시간·크기 최대), ③ IVF-Flat(nlist=64 군집 중 nprobe∈{8,32}만 탐색), ④ IVF-PQ(m=32 부분공간 ·6비트 양자화; 저장 8~13MB로 급감하나 재현율 0.33~0.49로 급락). 색인 설정 총 7개 × 조합 16개 = 112 구성.

2.

1. 배포 (RQ5) — 색인을 어떤 범위로 구축해 운영할지, 2개: ① 전역 색인(전체 데이터 단일 색인; 실측 시공간 군집 조건에서 재현율 손실 최대 0.627 — 동일 선택도 무작위 대조는 최대 0.047 변동에 그쳐 실제 손실을 과소평가), ② 조건별 부분 색인(자주 쓰는 조건별 부분집합만 별도 색인; 재현율 98.12~100% 회복). 배포 규칙: 전역 색인 재현율이 목표 0.95 미달 시 부분 색인(부분집합 HNSW)이나 전수 검색을 활성화하고, 부분 색인은 다음 색인 갱신 시점까지의 예상 질의 수가 해당 조건의 선택도별 손익분기점을 초과할 때만 구축한다. 복구 경로는 조건 종류·엔진에 따라 갈린다(시간 조건은 반복 스캔으로 지연 상승 없이 98%+ 회복, 군집 높은 장소 조건은 30~65% 회복에 지연 29.5ms 급증; Milvus/Weaviate는 필터 비율 약 92.3% 이상 또는 조건 만족 벡터 40,000개 미만이면 전수 검색 자동 전환으로 결손 0.0014 이하).

RQ: RQ5

조작 변인: 색인(Flat/HNSW/IVF/IVF-PQ)×배포(전역/부분)×조건(실측 군집 vs 무작위)

통제: 동일 선택도 짝 비교(시내도로 29쌍·교차로 25쌍), 단일 스레드/커넥션

데이터·지표: 13만~14만 벡터, 재현율@10·p50/p95·구축 초·MB

판정 근거: 전역 손실 최대 0.627, 부분 색인 98%+ 회복(표 7~10), 112구성 파레토(그림 3)

RQ 5. (물리적 벡터 색인과 배포 정책)

실제 센서 및 시공간 predicate의 선택도와 임베딩 공간 내 군집성이 **filtered-vector search**에 미치는 영향을 고려할 때, **Flat, HNSW, IVF-Flat 및 IVF-PQ** 중 어떤 색인 구조와 global, partial, local 및 hot/cold 배포 정책이 검색 재현율, 지연 시간, 색인 크기와 구축 비용을 가장 잘 균형화하는가?

filtered-vector search는 메타데이터를 활용한 일반 필터 조건에 벡터 검색을 동시에 수행하는 방법이다.

이는 prefilter, postfilter 방법을 통칭하는 용어이다.

hot/cold 배포 정책은 데이터의 '나이'와 '접근 빈도'에 따라 저장소와 검색 엔진의 스펙을 다르게 나누어 배치하는 비용 절감 정책을 의미한다. hot은 가장 최근에 수집(생성)된 이벤트의 벡터 데이터이며, 반대로 cold는 오래 전(1달~1년 등)에 저장되어 조회를 거의 하지 않을 데이터이다.

global, partial, local은 대용량 데이터를 가진 데이터베이스나 분산 시스템에서 "벡터 인덱스(색인)를 물리적/논리적으로 어디에, 어떻게 쪼개서 저장하고 관리할 것인가"에 대한 **색인 및 배포 범위 정책**을 의미한다.

구분	개념	장점	단점
Global (전역)	모든 데이터를 한 군데 뭉쳐서 거대한 단일 색인 하나만 만드는 정책	메타데이터 조건 없이 전체 데이터에서 유사한 벡터를 찾을 때 가장 정확함	데이터가 늘어날수록 메모리가 폭발하고, 필터 조건이 붙으면 검색이 느려짐
Partial (부분)	데이터를 시간/장소 등으로 쪼갠 뒤, 각 파티션 안에 각각의 색인 을 만드는 정책	"특정 시간, 특정 카메라"처럼 좁혀진 필터 조건 검색 시 속도가 압도적으로 빠름	필터 없이 전체 데이터를 검색하려면 모든 파티션을 다 뒤져야 해서 느려짐
Local (지역)	데이터 전체가 아니라 특정 조건을 만족하는 핵심 데이터만 골라 색인을 만드는 정책	자주 쓰지 않는 데이터(예: 노이즈, 오래된 데이터)를 제외해 메모리와 비용을 극대화하여 절약	색인에서 제외된 데이터를 검색할 때는 속도가 느린 전체 탐색(Flat)을 해야 함

RQ5. 물리적 벡터 색인과 배포 정책

같은 논리적 검색 방식도 어떤 물리적 색인과 배포 정책으로 실행하느냐에 따라 성능과 비용이 달라진다.

1 연구질문

Flat, HNSW, IVF-Flat, IVF-PQ와 global / partial / local / hot-cold 정책 중, 어떤 조합이 재현율·지연·색인 크기·구축 비용의 균형을 가장 잘 맞추는가?



2 벡터 색인 구조 비교

A. Flat

- 정확 검색 기준선
- 모든 벡터와 직접 비교
- 데이터가 커질수록 지연 증가

정확도 기준선

B. HNSW

- 그래프 기반 ANN
- 높은 재현율·빠른 탐색
- 메모리 사용량 큼

고재현율·빠른 질의

C. IVF-Flat

- 군집 일부만 탐색
- 속도와 재현율 조절 가능
- nprobe 같은 탐색 범위가 중요

조절형 절충

D. IVF-PQ

- IVF + 벡터 압축
- 저장 공간 크게 절감
- 압축 오차로 품질 저하 가능

저장비 절감형

3 색인 배포 정책

A. global index

전체 코퍼스를 하나의 공용 색인으로 구성

B. partial index

반복 사용 predicate 부분집합에 별도 색인

C. local index

지역·센서·교차로·시간대별 분리 색인

D. hot index

자주 쓰는 predicate에 미리 구축한 고속 색인

E. cold path

저빈도 predicate는 공용 색인 또는 Flat 검색 사용

4 왜 '선택도'만으로는 충분하지 않은가?

실제 predicate (선택도 5%)

통과 벡터가 특정 영역에 군집

VS

무작위 마스크 (선택도 5%)

통과 벡터가 공간 전체에 분산

같은 선택도라도 군집성(clustering)이 다르면 HNSW / IVF 탐색 효율이 달라질 수 있다.

RQ5는 실제 predicate와 동일 선택도의 무작위 마스크를 비교해, 성능 차이가 '비율' 때문인지 '공간 구조' 때문인지 구분한다.

5 주요 평가 조건

- predicate 선택도
- 임베딩 공간 내 군집성
- 전체 데이터 규모
- 질의 빈도
- ANN 재현율
- p50 / p95 검색 지연
- 색인 크기
- 색인 구축 시간
- 색인 갱신 비용
- 반복 질의에 따른 구축비 상각 가능성

6 운영 판단 기준

- 대규모 반복 검색 → HNSW 또는 IVF 계열 검토
- 선택도 높고 자주 쓰는 predicate → partial / local / hot index 유리 가능
- 저빈도·cold predicate → global index + postfilter 또는 Flat이 경제적일 수 있음
- 색인 구축비 회수 가능? → 질의 빈도가 손익분기점을 넘는지 계산 필요
- 끝까지 별도 색인이 불필요한 경우? → 낮은 빈도·낮은 상각 가능성 predicate



결론: RQ5의 목표는 '가장 빠른 색인 하나'를 찾는 것이 아니다.

predicate의 선택도, 군집성, 질의 빈도, 데이터 규모, 저장 예산을 함께 고려하여 언제 어떤 색인을 만들고 유지할지에 대한 운영 정책을 제시하는 것이 핵심이다.



벡터 색인 구조

색인	특징
Flat	모든 벡터와 직접 비교하는 정확 검색. 정확도 기준선이지만 데이터가 커질수록 지연이 증가함
HNSW	그래프 탐색을 이용하는 근사 최근접 이웃 검색. 높은 재현율과 빠른 검색을 제공하지만 메모리 사용량이 큼
IVF-Flat	벡터를 여러 군집으로 나누고 일부 군집만 검색. 속도와 재현율을 탐색 범위로 조절할 수 있음
IVF-PQ	IVF와 벡터 압축을 결합. 저장 공간을 크게 줄일 수 있지만 압축 오차가 발생함

색인 배포 정책

배포 정책	의미
global index	전체 코퍼스를 하나의 공용 색인으로 구성
partial index	반복적으로 사용되는 특정 predicate의 부분집합에 별도 색인을 구성
local index	지역, 센서, 교차로 또는 시간 구간별로 색인을 분리
hot index	질의 빈도가 높은 predicate 또는 데이터 구간에 미리 구축한 색인
cold path	저 빈도 predicate에 대해 별도 색인을 만들지 않고 공용 색인 또는 정확 검색을 사용

RQ5에서는 실제 predicate와 동일한 선택도를 가진 무작위 마스크를 비교한다. 이는 필터 성능이 단순히 통과 데이터의 비율 때문에 달라지는지, 아니면 해당 데이터가 임베딩 공간에서 특정 영역에 군집되어 있기 때문에 달라지는지를 구분하기 위한 것이다.

예를 들어 두 predicate의 선택도가 모두 5%라 하더라도 다음과 같은 차이가 있을 수 있다.

- 실제 predicate의 벡터들이 임베딩 공간의 특정 영역에 밀집되어 있음
- 무작위 마스크의 벡터들은 전체 공간에 고르게 흩어져 있음

두 경우에는 같은 선택도라도 HNSW나 IVF 탐색의 효율이 다르게 나타날 수 있다.
주요 평가 조건은 다음과 같다.

- predicate 선택도
- 임베딩 공간 내 군집성
- 전체 데이터 규모
- 질의 빈도
- ANN 재현율
- p50 및 p95 검색 지연
- 색인 크기
- 색인 구축 시간
- 색인 갱신 비용
- 반복 질의에 따른 구축비 상각 가능성

이를 바탕으로 다음과 같은 운영 판단 기준을 도출한다.

- 필터가 없는 대규모 반복 검색에서는 HNSW 또는 IVF 계열이 적절한가?
- 선택도가 높고 반복적으로 사용되는 predicate에는 partial 또는 local index가 유리한가?
- 저빈도 또는 cold predicate에는 global index와 postfilter 또는 Flat 검색이 더 경제적인가?
- 색인 구축 비용이 반복 질의의 지연 절감으로 회수되는 최소 질의 빈도는 얼마인가?
- 별도 색인을 구축해도 손익분기점에 도달하지 못하는 predicate는 무엇인가?

RQ5의 목표는 predicate별 질의 빈도와 선택도, 데이터 규모 및 저장 예산을 고려하여 **언제 어떤 색인을 만들고 유지해야 하는지에 관한 운영 정책**을 제시하는 것이다.

▼ RQ6. VLM 응답 전파

RQ: RQ6

조작 변인: 증거 품질 4단계(무증거/무관/벡터 검색/대상 설명문) + 카메라 시점

통제: 질의·모델 고정

데이터·지표: VLM 답변 정확도

판정 근거: 31→53→67→75% 단조 증가, 단일 시점 +15.2%p; 색인 재현율 전파는 표본 부족으로 탐색적

RQ 6. (DB 증거 검색 개선의 최종 VLM-QA 전파)

DB 증거 계층에서 발생한 검색 품질과 벡터 색인 재현율의 차이는 최종 VLM-QA 정확도로 어느 정도 전파되는가? 그리고 코퍼스 규모, VLM의 지각 능력, 질문 설계 및 응답 편향은 이러한 전파를 어떻게 제한하는가?

데이터베이스 검색 계층에서 성능이 좋아졌다고 해서 최종 답변 생성 모델(VLM, LLM) 또한 성능이 좋아지는 것은 아니다. 검색 결과가 전파되는 과정에서 여러가지 잠재적 병목이 존재하기 때문이다. 이를 분리하여 평가하기 위해 RQ6에서는 **VLM 모델, 프롬프트 및 답변 생성 조건을 고정하고, 입력되는 증거 집합만 변경한다.**

이를 통해 최종 답변 차이가 검색 결과에서 비롯된 것인지 최대한 분리하여 분석한다.

RQ6. DB 증거 검색 개선의 최종 VLM-QA 전파

검색 품질 향상이 언제 최종 VLM-QA 정확도 향상으로 이어지고, 언제 막히는가?

RQ6는 검색-색인 차이가 최종 답변으로 자동 전환된다고 가정하지 않고, 전파를 가능하게 하는 조건과 병목을 분리해 분석한다.


1 연구질문

DB 증거 계층의 검색 품질과 벡터 색인 재현을 차이는 최종 VLM-QA 정확도로 얼마나 전파되는가?
또한 코퍼스 규모, VLM의 지각 능력, 질문 설계, 응답 편향은 이 전파를 어떻게 제한하는가?



통제된 평가 설계:
VLM 모델, 프롬프트, 생성 조건은 고정하고, 입력 증거 집합만 바꿔 최종 답변 차이와 일련의 검색 결과 쪽으로 최대한 분리한다.

2 전파 경로와 병목



핵심: 검색이 좋아져도, 증거 구성과 VLM 해석이 병목이면 최종 답변은 좋아지지 않을 수 있다.

3 RQ6에서 검증하는 다섯 가지 경계

6.1 코퍼스 규모 경계

- 소규모 코퍼스에서는 Flat, HNSW, IVF가 거의 같은 증거를 반환할 수 있음
- 지연 차이는 있어도 최종 답변 차이는 작을 수 있음

6.2 VLM 지각 경계

- 더 좋은 증거가 있어도 VLM이 작은 객체, 미세한 신호-가려진 대상을 인식 못하면 성능 차이에 의함
- 공간 관계 해석 실패도 병목

6.3 질문 설계 경계

- 단일 프레임만으로는 이동 방향-신호 변화-사고 전후 관계 판단이 어려움
- 이 경우 검색 품질보다 시각적 증거 구성 방식이 더 중요할 수 있음

6.4 응답 편향 경계

- 특정 객체나 문구가 정답과 무관하게 응답을 확률적으로 유도할 수 있음
- 증거가 많다고 항상 유리하지 않음

6.5 증거 수량과 적합성 경계

- 정답 장면 포함 확률은 늘어날 수 있지만, 무관한 증거도 함께 늘어날 수 있음
- 양보다 적합성과 구성 방식이 중요

4 증거 집합 비교 실험

A. 적은 수의 고품질 증거

노이즈 적음, 핵심 장면 집중

B. 많은 수의 혼합 품질 증거

정답 포함 확률 ↑, 혼란도 ↑

C. 중복 프레임이 많은 증거

정보량은 적고 중복은 큼

D. 서로 보완적인 장면으로 구성된 증거

시간/공간 단서를 함께 제공

RQ6는 단순히 '더 많은 증거'가 아니라, '어떤 증거 조합이 VLM 판단에 실제로 도움이 되는가'를 비교한다.

5 전파가 잘 일어나는 조건 vs 차단되는 조건

전파가 잘 일어나는 조건

- ✓ 검색된 증거가 실제 정답 장면을 포함함
- ✓ 증거들이 서로 보완적이며 노이즈가 적음
- ✓ VLM이 필요한 시각 단서를 해석할 수 있음
- ✓ 질문이 제공된 증거 형태와 잘 맞음

VS

전파가 차단되는 조건

- ⚠ 색인 차이가 실제 증거 차이로 이어지지 않음
- ⚠ 좋은 증거가 있어도 VLM이 인식-추론 못함
- ⚠ 시간 정보가 필요한 질문인데 증거가 정적임
- ⚠ 무관하거나 편향적인 증거가 판단을 혼동

6 핵심 해석 포인트



결론: 검색 품질 향상은 최종 VLM-QA 향상으로 자동 전환되지 않는다.

- 1 검색 차이가 최종 답변 차이로 전파되려면, 증거 차이가 실제로 의미 있어야 한다.
- 2 VLM의 지각 능력과 증거 설계가 전파의 성능을 결정할 수 있다.
- 3 따라서 RQ6의 핵심은 색인, 검색 개선이 아니라, 검색 개선이 최종 답변으로 이어지는 조건과 실패 원인을 구분하는 것이다.

RQ6에서는 다음 경계를 검증한다.

6.1 코퍼스 규모 경계

소규모 코퍼스에서는 Flat, HNSW 및 IVF가 실제로 거의 동일한 증거를 반환할 수 있다.

이 경우 색인별 지연 차이는 존재하더라도 최종 답변 차이는 나타나지 않을 수 있다.

6.2 VLM 지각 경계

더 적절한 증거가 검색되더라도 VLM이 작은 객체, 미세한 신호 상태, 가려진 대상 또는 복잡한 공간 관계를 인식하지 못하면 답변 정확도는 개선되지 않는다.

6.3 질문 설계 경계

단일 프레임만으로는 차량의 이동 방향, 신호의 변화, 사고 전후 관계 등 시간적 상태를 판단할 수 없다.

이러한 질문에서는 검색 품질보다 증거의 시간적 구성 방식이 더 중요한 제약이 될 수 있다.

6.4 응답 편향 경계

검색된 증거의 특정 객체나 문구가 실제 정답과 무관하게 VLM의 응답을 특정 방향으로 유도할 수 있다. 따라서 증거가 많아지는 것이 항상 유리하지 않을 수 있다.

6.5 증거 수량과 적합성의 경계

더 많은 증거를 제공하면 정답 장면이 포함될 확률은 높아지지만, 무관한 증거가 증가하여 VLM의 판단을 방해할 수도 있다. 따라서 다음을 비교한다.

- 적은 수의 고품질 증거
- 많은 수의 혼합 품질 증거
- 중복 프레임이 많은 증거
- 서로 보완적인 장면으로 구성된 증거

RQ6은 검색 품질 향상이 최종 답변 향상으로 자동 전환된다고 가정하지 않는다. 검색·색인 차이가 최종 답변으로 전파되기 위해 필요한 조건과, 그 전파가 차단되는 원인을 규명하는 것이 목적이다.

▼ 정답 기준의 이원화 해석

	엄격한 정답 (Strict Ground Truth)	의미론적 정답 (Semantic Ground Truth)
조건의 해석	필수 제약 (Hard constraint)	관심 단서 (Soft cue)
정답 집합 정의	의미 조건 n 메타데이터 조건	의미 조건을 만족하는 모든 클립이 정답
출처	사람 주석 n 센서 기록	사람 주석
평가 기준	조건 준수 능력	조기 누락 여부
규모	qrels 6,809행	qrels 24,872행

구축 절차 (5.1.1절)

메타데이터 필드의 구체적 조건 22개 × 의미 조건 5종(주차 차량, 개체 20개 이상, 버스 2대 이상, 정차 차량·이륜차 2대 이상 등)을 조합해 후보 질의 110개를 만들고, 두 조건을 함께 만족하는 클립이 5개 이상인 질의 85개를 확정했다. **의미 조건 판정은 사람 주석, 메타데이터 조건 판정은 센서 기록에서 나오므로 정답 생성 경로가 검색 문서(VLM 설명문)와 분리되어 있다.**

▼ 5가지 메타데이터 카테고리별 22개의 독립 조건값

- 시간대 (time_of_day) - 3개
 - morning (오전)
 - afternoon (오후)
 - evening (저녁) (새벽/야간 데이터 제외)
- 황색 신호 여부 (sig_has_yellow) - 2개
 - True (황색 신호 있음)
 - False (황색 신호 없음)
- 보행 신호 여부 (sig_has_pedestrian) - 2개
 - True (보행 신호 있음)
 - False (보행 신호 없음)
- 센서 교통 밀도 (veh_density_bin) - 3개
 - low (저밀도)
 - mid (중밀도)
 - high (고밀도)
- 특정 시각 (hour) - 12개
 - 6시, 7시, 8시, 9시, 13시, 14시, 15시, 16시, 17시, 18시, 19시, 20시 (주요 관측 시각 12개)

▼ 질의 85개 추출 구조

- 후보 질의 조합 (110개): 메타데이터 구체적 조건값 22개 × 의미 조건 5종 (주차 차량, 개체 20개 이상, 버스 2대 이상, 정차 차량, 이륜차 2대 이상) = 110 개의 후보 질의 조합 생성

2. 최종 질의 확정 (85개): 110개 조합 중 **두 조건**을 동시에 만족하는 데이터(양성 샘플)가 5개 이상 존재하는 질의 85개를 최종 검증 **작업 부하(Workload)**로 확정함.

각 기준의 대표 결과와 해석 주의

엄격한 정답 기준. 검색 전 조건 적용이 벡터 단독 대비 $\Delta +0.0983$ (CI [+0.068, +0.133])으로 유의하게 우세하다. 단, 논문은 이를 "조건 충족이 정답 정의에 강제되어 발생한 자명한 결과"로 해석한다.

- 엄격한 정답 자체가 메타데이터 조건 만족을 포함하므로, 조건을 먼저 걸면 정답 후보만 남는 것이 구조적으로 당연하기 때문이다.
- 같은 이유로 RQ4에서 **메타데이터 단독 신호**가 0.218로 가장 높게 나오며, 이는 검색기의 순위화 능력이 아니라 조건-정답 간 물리적 결합도를 반영한다. 보고서에서 이 수치를 "prefilter의 우수성"으로 단독 인용하면 안 된다.

의미론적 정답 기준. 조기 누락 위험 때문에 벡터 단독 검색이 0.170으로 최고이고, 검색 전 0.154 > 검색 후 0.150 > 혼합 0.133 순이다. 단, 집계 차이 $\Delta = -0.0158$ 은 CI가 0을 포함해 무의미하며, 결합도 총화에서 고결합(Cramér's $V \geq 0.3$) 질의에서는 검색 전 적용이 +0.1335로 유의한 이득으로 반전된다.

- "필터는 해롭다"가 아니라 "필터의 가치는 조건-관련성 결합도에 조건부"가 정확한 결론이다. RQ2에서도 다중 이미지의 이득(0.352, $\Delta +0.171$)은 의미론적 기준에서만 유의하다(엄격 기준 0.101).
- 평균 차이 : 전체 85개 질문의 평균을 내보니, "필터를 적용한 것(0.154)"이 "필터를 안 쓴 것(0.170)"보다 평균 점수가 -0.0158 약간 낮았습니다. 하지만 **통계적 신뢰구간(CI)**을 측정해보니 **0을 포함하고 있어서**, "전체 질문을 통틀어 봤을 때는 필터를 쓴 것과 안 쓴 것의 평균 차이가 통계적으로 뚜렷하지 않다(무의미하다)"는 결론에 도달한다.

'결합도(Cramér's $V \geq 0.3$)에 따른 반전'의 의미

- **저결합 질문 (연관성 낮음)** : 황색 신호 여부 × 주차 차량 : 신호 상태와 주차 존재는 서로 독립적이어서(실측 $V=0.005$ 수준) 필터가 관련 장면을 이유 없이 잘라낸다.
- **고결합 질문 (연관성 매우 높음)** : 센서 교통 밀도 × 개체 20개 이상 : 센서가 켜진 밀도와 장면 속 개체 수는 자연히 얽혀 있어 필터가 관련 장면을 거의 잃지 않으면서 후보를 좁힌다.

최종 결론: 연구가 말하고자 하는 바

- "필터링(검색 전 조건 적용)은 무조건 성능을 떨어뜨리는 나쁜 기법이다!"라고 단정 지으면 안 된다.
- 진짜 결론은 "필터가 약이 될지 독이 될지는 '검색 조건'과 '사용자가 찾으려는 내용'이 얼마나 밀접하게 연결되어 있는지(결합도)에 따라 결정된다"는 것이다.
- 조건과 질문의 연관성이 높다면(**고결합**) : **사전 필터를 적용**해야 검색 속도와 정확도가 모두 뛰어납니다.
- 조건과 질문의 연관성이 약하다면(**저결합**) : 필터를 적용하지 않고 **벡터 단독 검색**을 하는 것이 조기 누락을 막아 훨씬 유리하다.

'다중 이미지' 언급의 의미

영상 하나당 이미지를 여러 장(예: 3장) 저장하는 다중 이미지 기법은 영상의 풍부한 시각적 변화를 다 잡아내므로 '의미론적 정답 기준(0.352)'에서는 품질 향상 효과가 매우 압도적이다. 하지만 필터 조건만 간간하게 따지는 '엄격한 정답 기준(0.101)'에서는 그 시각적 풍부함의 가치가 제대로 발휘되지 못한다는 점을 짚어주는 비유적 사례이다.

공통 개념과 평가 계약

메타데이터 조건식

메타데이터 조건식(Predicate)는 장소, 시간, 센서 상태, 신호 상태, 객체 유형 등 구조화된 메타데이터에 적용되는 검색 조건을 의미한다.

? 교차로 A에서 오후 6시 이후에 촬영되었으며 보행자 신호가 활성화된 영상

이 조건은 질의의 성격에 따라 반드시 만족해야 하는 **경성 조건(hard constraint)**으로 해석될 수도 있고, 사용자의 선호를 표현하는 **연성 의도(soft intent)**로 해석될 수도 있다.

Strict relevance와 Semantic relevance

본 연구는 필터 계획을 공정하게 평가하기 위해 정답 기준을 두 가지로 분리한다.

정답 기준	의미
Strict relevance	의미적으로 관련될 뿐 아니라, 지정된 메타데이터 predicate도 만족해야 정답으로 인정한다.
Semantic relevance	predicate 만족 여부와 별개로, 질의의 의미에 적합한 증거이면 정답으로 인정한다.

Strict 평가에서는 predicate가 사용자의 명시적 요구 조건이므로 prefilter의 사용이 정당할 수 있다. 반면 semantic 평가에서는 메타데이터가 부정확하거나 불완전할 경우 prefilter가 의미상 유용한 증거를 제거할 수 있다. 따라서 본 연구는 단순히 “prefilter가 우수한가?”를 묻지 않는다. 대신 다음을 묻는다.

? 어떤 질의 제약과 **predicate-relevance 결합도**에서 어떤 필터 계획이 적절한가?

여기서 **predicate-relevance 결합도**란 predicate를 만족하는 문서와 실제 의미상 관련 문서가 얼마나 일치하는지를 의미한다.

▼ RQ에서의 공통 평가 축

RQ2부터 RQ5까지는 동일한 평가 축을 사용하여 결과를 일관되게 비교한다.

RQ6에서는 여기에 최첨단 품질을 추가한다.

평가 영역	주요 지표	평가 목적
검색 품질	nDCG@k, MRR@k, Recall@k	관련 증거가 검색 결과의 상위에 얼마나 정확히 배치되는지 평가
검색 지연	p50, p95	일반적인 응답 시간과 최악 구간의 지연을 함께 평가
저장 비용	원본 벡터 크기, 색인 크기	증거 표현 및 색인 구조가 요구하는 저장 공간 평가
구축 비용	임베딩 생성 시간, 색인 구축 시간	시스템 초기 구성 비용 평가
운영 비용	질의 빈도별 구축비 상각, 갱신 비용	별도 색인을 장기간 운영할 경제적 타당성 평가
색인 정확도	exact search 대비 ANN recall	근사 색인으로 인해 실제 검색 결과가 얼마나 달라지는지 평가
답변 품질	고정 VLM의 최종 QA 정확도	검색 계층의 차이가 최종 사용자 답변으로 전달되는지 평가

모든 검색 품질 결과는 **strict relevance**와 **semantic relevance**를 분리하여 보고한다.

또한 가능한 경우 동일한 질의와 동일한 코퍼스에 대한 대응 비교를 사용하여, 데이터 난이도 차이가 검색 방식의 효과로 오인되지 않도록 한다.

▼ 데이터셋